

# 経営学への応用を目指す AI 入門：数学演習問題集

第 1 回～第 5 回 講義内容完全準拠・論理展開追体験セット（完全版）

特殊講義 1 補助資料

2026 年 5 月 17 日（最終更新）

最終更新日：2026 年 5 月 17 日（v1.0）

## 本演習問題集の進め方と活用法

本問題集は、講義スライドに登場する数式の「行間（省略された計算や証明）」を学生自身の手で動かして埋め、ブラックボックスを解消することを目的に設計されています。各セクションには講義スライドとの対応関係である【該当内容】と、その演習を行う目的である【ねらい】が記載されています。

また、各設問には以下の難易度が設定されています。

- 難易度：★ 0 (Basic)：スライドの定義そのものの確認や、直感的な代入問題。
- 難易度：★ 1 (Standard)：講義の数式展開を再現する標準的な手計算。
- 難易度：★ 2 (Advanced)：行列の微分や文字式による一般的な証明など、一步進んだ数学的体力を要する問題。

## 【第 1 回】確率の基礎とリスク関数・ERM

### 1-1. 確率の基礎と期待値・分散の計算

#### 問 1 離散型確率分布での期待値・分散計算

難易度：★ 0

ある離散確率変数  $X$  は、確率 0.2 で 0、確率 0.5 で 1、確率 0.3 で 2 をとる。

1. 期待値  $\mathbb{E}[X]$  を求めよ。
2.  $f(x) = x^2$  とするとき、その期待値  $\mathbb{E}[f(X)]$  を求めよ。
3. 公式  $\mathbb{V}[f(X)] = \mathbb{E}[(f(X))^2] - (\mathbb{E}[f(X)])^2$  を用いて、分散  $\mathbb{V}[f(X)]$  を計算せよ。

[解答・解説へ]

#### 問 2 連続型確率分布での期待値・分散計算

難易度：★ 1

連続確率変数  $X$  の確率密度関数が以下で与えられている（それ以外の範囲では 0）。

$$p(x) = 2x \quad (0 \leq x \leq 1)$$

1.  $\int_0^1 p(x)dx = 1$ （全確率が 1）が満たされていることを示せ。
2. 期待値  $\mathbb{E}[X] = \int_0^1 xp(x)dx$  を計算せよ。
3.  $\mathbb{E}[X^2] = \int_0^1 x^2p(x)dx$  を計算し、分散  $\mathbb{V}[X]$  を求めよ。

## 問 3 共分散 (Covariance) の 2 次形式的振る舞い

難易度：★ 1

確率変数  $X, Y, Z$  と定数  $a, b$  について、共分散の性質 (双線形性・対称性)

$$\text{Cov}(aX + bY, Z) = a\text{Cov}(X, Z) + b\text{Cov}(Y, Z)$$

$$\text{Cov}(X, Y) = \text{Cov}(Y, X)$$

を用いて、次の式を展開せよ。

1.  $\text{Cov}(X, X + Y)$
2.  $\mathbb{V}[aX + bY]$  (ヒント:  $\mathbb{V}[Z] = \text{Cov}(Z, Z)$  であることを利用せよ)

[解答・解説へ]

## 1-1. の解答・解説

【該当内容】第 1 回スライド 34~38 「基本知識>確率分布、期待値」【ねらい】期待値  $\mathbb{E}[\cdot]$  や分散  $\mathbb{V}[\cdot]$  の計算規則を、離散型・連続型の両面から手計算で確かめ、のちに登場する「リスク関数」の数学的実態を掴む。

## 問 1 の解答・解説

1.  $\mathbb{E}[X] = 0 \times 0.2 + 1 \times 0.5 + 2 \times 0.3 = 0 + 0.5 + 0.6 = 1.1$
2.  $\mathbb{E}[f(X)] = \mathbb{E}[X^2] = 0^2 \times 0.2 + 1^2 \times 0.5 + 2^2 \times 0.3 = 0 + 0.5 + 1.2 = 1.7$
3. まず  $\mathbb{E}[(f(X))^2] = \mathbb{E}[X^4]$  を計算する。

$$\mathbb{E}[X^4] = 0^4 \times 0.2 + 1^4 \times 0.5 + 2^4 \times 0.3 = 0 + 0.5 + 16 \times 0.3 = 5.3$$

これと (2) の結果  $\mathbb{E}[f(X)] = 1.7$  を公式に代入する。

$$\mathbb{V}[f(X)] = 5.3 - (1.7)^2 = 5.3 - 2.89 = 2.41$$

[問題へ戻る]

## 問 2 の解答・解説

1.

$$\int_0^1 2x dx = [x^2]_0^1 = 1^2 - 0^2 = 1 \quad (\text{証明終})$$

2.

$$\mathbb{E}[X] = \int_0^1 x(2x) dx = \int_0^1 2x^2 dx = \left[ \frac{2}{3} x^3 \right]_0^1 = \frac{2}{3}$$

3.  $\mathbb{E}[X^2]$  の計算:

$$\mathbb{E}[X^2] = \int_0^1 x^2(2x) dx = \int_0^1 2x^3 dx = \left[ \frac{1}{2} x^4 \right]_0^1 = \frac{1}{2}$$

よって分散  $\mathbb{V}[X]$  は、

$$\mathbb{V}[X] = \frac{1}{2} - \left( \frac{2}{3} \right)^2 = \frac{1}{2} - \frac{4}{9} = \frac{1}{18}$$

[問題へ戻る]

### 問 3 の解答・解説

1.

$$\text{Cov}(X, X + Y) = \text{Cov}(X, X) + \text{Cov}(X, Y) = \mathbb{V}[X] + \text{Cov}(X, Y)$$

2.

$$\begin{aligned}\mathbb{V}[aX + bY] &= \text{Cov}(aX + bY, aX + bY) \\ &= a^2 \text{Cov}(X, X) + ab \text{Cov}(X, Y) + ba \text{Cov}(Y, X) + b^2 \text{Cov}(Y, Y) \\ &= a^2 \mathbb{V}[X] + 2ab \text{Cov}(X, Y) + b^2 \mathbb{V}[Y] \quad (\text{対称性より})\end{aligned}$$

この展開の構造は、のちに行列やベクトルの内積（2 次形式）を展開する際の論理構造と全く同じである。

[問題へ戻る]

## 1-2. リスク関数 and 経験リスク

### 問 4 分布が既知の場合の真のリスク関数

難易度：★ 1

あるデータ生成分布において、入力  $X$  は常に 1 で固定されており、ラベル  $Y$  は確率 0.6 で  $y = 3$ 、確率 0.4 で  $y = 8$  をとるとする。予測器を定数  $c$  を出力するモデル  $f(x) = c$  とし、損失関数を二乗誤差  $l(y, c) = (y - c)^2$  とする。

1. このときの真のリスク関数  $R(c) = \mathbb{E}[l(Y, c)]$  の式を  $c$  の関数として書き下せ。
2.  $c = 5$  のときの真のリスクの値を求めよ。

[解答・解説へ]

### 問 5 経験リスクの計算と予測値の代入

難易度：★ 0

上記のデータ生成分布から、現実世界でランダムに  $n = 3$  個のサンプルを収集したところ、偶然にも全て  $y_1 = 3, y_2 = 3, y_3 = 3$  であったとする。

1. この手元の標本に対する経験リスク  $\hat{R}(c)$  の式を書き下せ。
2.  $c = 5$  のときの経験リスクの値を計算し、問 1 の真のリスク値との違いを考察せよ。

[解答・解説へ]

## 1-2. の解答・解説

**【該当内容】** 第 1 回スライド 78～86「予測系タスクの学習>リスク関数、リスクの標本近似」**【ねない】** 未来のあらゆるデータを考慮した「真のリスク（期待値）」と、手元にあるデータから計算する「経験リスク（標本平均）」の関係を具体的に数値で比較し、そのギャップを理解する。

### 問 4 の解答・解説

1.

$$R(c) = 0.6 \times (3 - c)^2 + 0.4 \times (8 - c)^2$$

2.  $c = 5$  を代入すると、

$$R(5) = 0.6 \times (3 - 5)^2 + 0.4 \times (8 - 5)^2 = 0.6 \times 4 + 0.4 \times 9 = 2.4 + 3.6 = 6.0$$

[問題へ戻る]

### 問 5 の解答・解説

1.

$$\hat{R}(c) = \frac{1}{3} \sum_{i=1}^3 (y_i - c)^2 = \frac{1}{3} [(3-c)^2 + (3-c)^2 + (3-c)^2] = (3-c)^2$$

2.  $c = 5$  を代入すると、

$$\hat{R}(5) = (3-5)^2 = 4.0$$

**【考察】** 真のリスク  $R(5) = 6.0$  に対し、経験リスクは  $\hat{R}(5) = 4.0$  となり大きく乖離している。これはデータ生成分布  $p(y)$  が未知で、手元のサンプリング（標本）に偏りがあるために生じる。機械学習では真のリスクが計算できないため、この経験リスクを代わりに最小化する（ERM）。

[問題へ戻る]

## 1-3. ERM（経験リスク最小化）

### 問 6 目的関数のパラメータ関数化

難易度：★ 0

データポイント  $(x_1, y_1) = (1, 2)$  および  $(x_2, y_2) = (3, 4)$  がある。予測モデルを原点を通る直線  $f_\theta(x) = \theta x$  とし、損失関数を二乗誤差とする。このとき、経験リスク

$$\hat{R}(f_\theta) = \frac{1}{2} \sum_{i=1}^2 (y_i - f_\theta(x_i))^2$$

に具体的な数値を代入し、 $\theta$  の 2 次関数  $A\theta^2 + B\theta + C$  の形に展開・整理せよ。

[解答・解説へ]

### 1-3. の解答・解説

**【該当内容】** 第 1 回スライド 86～87「予測系タスクの学習＞経験リスク最小化（ERM）」**【ねらい】** 経験リスクの式に具体的なモデル式を代入し、目的関数が「入力  $x$  の関数」から「最適化すべきパラメータ  $\theta$  の関数」へと変貌する様子を確認する。

### 問 6 の解答・解説

与えられた数値を代入して整理する。

$$\begin{aligned}\hat{R}(\theta) &= \frac{1}{2} [(2 - \theta \cdot 1)^2 + (4 - \theta \cdot 3)^2] \\ &= \frac{1}{2} [(4 - 4\theta + \theta^2) + (16 - 24\theta + 9\theta^2)] \\ &= \frac{1}{2} (10\theta^2 - 28\theta + 20) \\ &= 5\theta^2 - 14\theta + 10\end{aligned}$$

これによって、最適化（微分して最小値を求める）対象がパラメータ  $\theta$  だけの関数になったことが示される。

[問題へ戻る]

## 【第2回】最適化と最小二乗法・偏微分

### 2-1. 経験リスクの数式化（シグマを用いた書き下し）

#### 問7 経験リスクの立式

難易度：★0

$n$  個の訓練データ  $\{(x_i, y_i)\}_{i=1}^n$  が与えられている。モデルクラスとして1次関数  $f_{(w,b)}(x) = wx + b$  を採用し、損失関数を二乗誤差  $l(y, \hat{y}) = (y - \hat{y})^2$  とするとき、目的関数  $L(w, b)$  を  $\sum_{i=1}^n$  を用いて書き下せ。

[解答・解説へ]

#### 問8 最適化問題の定式化：穴埋め

難易度：★0

以下の最適化問題の定式化について、空欄 [A] ～ [D] に入る適切な数式や記号を答えよ。

1. 【制約なし】パラメータ  $\theta$  を調整して、目的関数  $L(\theta)$  を最小にする「最適なパラメータ  $\hat{\theta}$ 」を求める問題：

$$\hat{\theta} = \arg \min_{[A]} [B]$$

2. 【制約あり】パラメータの大きさ（L2 ノルム） $\|\theta\|$  が定数  $C$  を超えないという制約のもとで、目的関数  $L(\theta)$  の最小値を求める問題：

$$\text{Min}_{[C]} L(\theta) \quad \text{subject to} \quad [D]$$

[解答・解説へ]

### 2-1. の解答・解説

【該当内容】第2回スライド27～37「予測系タスクの具体例＞線型単回帰、最小二乗法」【ねらい】 $n$  個の一般的なデータ表記に対して、二乗損失を用いた経験リスクの正確な数式をシグマ  $\sum$  を用いて構築できるようにする。

#### 問8 の解答・解説

1. [A] =  $\theta$ , [B] =  $L(\theta)$

よって全体の式は  $\hat{\theta} = \arg \min_{\theta} L(\theta)$  となる。最適化の目標（最小値）ではなく、最小値を与える「パラメータそのもの」を求めたい場合には  $\arg \min$  を用いる。

2. [C] =  $\theta$ , [D] =  $\|\theta\| \leq C$

よって全体の式は  $\text{Min}_{\theta} L(\theta) \quad \text{subject to} \quad \|\theta\| \leq C$  となる。制約条件は  $\text{subject to (s.t.)}$  の右側に記述する。

[問題へ戻る]

#### 問7 の解答・解説

モデルの出力  $\hat{y}_i = wx_i + b$  を損失関数に代入し、その標本平均をとる。

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

[問題へ戻る]

## 2-2. 最小二乗法の真髄：偏微分から一階の条件へ

### 問 9 偏微分と勾配ベクトルの書き下し

難易度：★ 1

目的関数  $L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - wx_i - b)^2$  とする。

1.  $L(w, b)$  を  $w$  について偏微分した式  $\frac{\partial L}{\partial w}$  を求めよ。(合成関数の微分に注意せよ)
2.  $L(w, b)$  を  $b$  について偏微分した式  $\frac{\partial L}{\partial b}$  を求めよ。
3. 勾配ベクトル  $\nabla L(w, b)$  の定義に従い、(1)(2) の結果を並べた列ベクトルを表記せよ。

[解答・解説へ]

### 問 10 一階の条件からの式変形

難易度：★ 2

最適解において勾配ベクトルがゼロになるという一階の条件  $\nabla L(w, b) = \mathbf{0}$  のうち、 $\frac{\partial L}{\partial b} = 0$  の式を変形し、最適な切片  $\hat{b}$  が、サンプルの平均値  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ,  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  を用いて

$$\hat{b} = \bar{y} - w\bar{x}$$

と表せることを証明せよ。

[解答・解説へ]

### 問 11 学習済みパラメータによる新規データの予測

難易度：★ 0

あるデータセットに対して最小二乗法を適用したところ、学習済みパラメータが  $\hat{w} = 2.5, \hat{b} = 1.0$  と求まった。このとき、新規に観測された特徴量  $x_{\text{new}} = 6$  に対する予測値  $\hat{y}_{\text{new}}$  を計算せよ。

[解答・解説へ]

## 2-2. の解答・解説

【該当内容】第 2 回スライド 38~45 「一階の条件、偏微分・勾配」【ねらい】スライドで省略されている目的関数  $L(w, b)$  の偏微分から勾配ベクトルの構築、一階の条件による正規方程式のスカラ版の導出を完全に追体験する。

### 問 9 の解答・解説

1. 合成関数の微分（チェインルール）を用いる。カッコの中身を  $w$  で微分した  $-x_i$  が外に出る。

$$\frac{\partial L}{\partial w} = \frac{1}{n} \sum_{i=1}^n 2(y_i - wx_i - b) \cdot (-x_i) = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b)x_i$$

2. 同様に、中身を  $b$  で微分した  $-1$  が外に出る。

$$\frac{\partial L}{\partial b} = \frac{1}{n} \sum_{i=1}^n 2(y_i - wx_i - b) \cdot (-1) = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b)$$

3. 勾配ベクトルは偏微分を縦に並べたものである。

$$\nabla L(w, b) = \begin{pmatrix} \frac{\partial L}{\partial w} \\ \frac{\partial L}{\partial b} \end{pmatrix} = \begin{pmatrix} -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b)x_i \\ -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) \end{pmatrix}$$

[問題へ戻る]

### 問 10 の解答・解説

一階の条件  $\frac{\partial L}{\partial b} = 0$  より、

$$-\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) = 0$$

両辺を  $-\frac{2}{n}$  で割り、和を分割する。

$$\sum_{i=1}^n y_i - w \sum_{i=1}^n x_i - \sum_{i=1}^n b = 0$$

定数  $b$  を  $n$  回足すと  $nb$  になるので、

$$\sum_{i=1}^n y_i - w \sum_{i=1}^n x_i - nb = 0$$

両辺を  $n$  で割ると、

$$\frac{1}{n} \sum_{i=1}^n y_i - w \left( \frac{1}{n} \sum_{i=1}^n x_i \right) - b = 0$$

平均値の定義  $\bar{x}, \bar{y}$  を代入すると、

$$\bar{y} - w\bar{x} - b = 0 \quad \Rightarrow \quad \hat{b} = \bar{y} - w\bar{x}$$

が導かれる。(証明終)

[問題へ戻る]

### 問 11 の解答・解説

学習済みモデル  $f(x) = \hat{w}x + \hat{b}$  に数値を代入する。

$$\hat{y}_{\text{new}} = 2.5 \times 6 + 1.0 = 15.0 + 1.0 = 16.0$$

[問題へ戻る]

## 【第 3 回】線型モデルの行列表現と正則化・モデル選択

### 3-1. ベクトルの内積と性質

#### 問 12 内積の計算と幾何的解釈

難易度：★ 0

2つのベクトル  $\mathbf{a} = (2, 3)^\top$ ,  $\mathbf{b} = (-6, 4)^\top$  がある。

1. 内積  $\mathbf{a}^\top \mathbf{b}$  を計算せよ。
2. この2つのベクトルの幾何学的な位置関係（同じ方向、逆方向、直交のいずれか）を特定せよ。

[解答・解説へ]

#### 問 13 射影成分の計算

難易度：★ 1

大きさ（ノルム）が 1 である方向ベクトル  $\mathbf{u} = (1, 0)^\top$  がある。任意のベクトル  $\mathbf{x} = (5, -3)^\top$  を  $\mathbf{u}$  方向の成分に射影したときの係数（射影の長さ）を内積を用いて計算せよ。

[解答・解説へ]

任意の次元のベクトル  $\mathbf{x}, \mathbf{y}$  およびスカラー  $c$  について、

$$\begin{aligned}\mathbf{x}^\top \mathbf{y} &= \mathbf{y}^\top \mathbf{x} \quad (\text{対称性}) \\ (c\mathbf{x})^\top \mathbf{y} &= c(\mathbf{x}^\top \mathbf{y}) \quad (\text{線形性})\end{aligned}$$

が成り立つことを、各成分を明示して確かめよ。

[解答・解説へ]

### 3-1. の解答・解説

【該当内容】第3回スライド 22～26 「線型モデルの幾何学的解釈、内積の性質」【ねらい】機械学習における予測の基本演算である「内積」について、重み付き和、幾何的な向きを検出、射影という3つの側面を手計算を通じて習得する。

#### 問 12 の解答・解説

1.

$$\mathbf{a}^\top \mathbf{b} = 2 \times (-6) + 3 \times 4 = -12 + 12 = 0$$

2. 内積が 0 であるため、2 つのベクトルは直交している。

[問題へ戻る]

#### 問 13 の解答・解説

求める射影の長さは内積  $\mathbf{x}^\top \mathbf{u}$  で与えられる。

$$\mathbf{x}^\top \mathbf{u} = 5 \times 1 + (-3) \times 0 = 5$$

よって  $\mathbf{u}$  方向への射影の長さは 5 である。

[問題へ戻る]

#### 問 14 の解答・解説

$\mathbf{x} = (x_1, \dots, x_d)^\top$ ,  $\mathbf{y} = (y_1, \dots, y_d)^\top$  とおく。

1. 内積の定義より  $\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d x_i y_i$  である。実数の積は可換 ( $x_i y_i = y_i x_i$ ) なので、

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d y_i x_i = \mathbf{y}^\top \mathbf{x}$$

となり、対称性が成立する。

2. ベクトルのスカラー倍の定義より  $c\mathbf{x} = (cx_1, \dots, cx_d)^\top$  である。

$$(c\mathbf{x})^\top \mathbf{y} = \sum_{i=1}^d (cx_i) y_i = c \sum_{i=1}^d x_i y_i = c(\mathbf{x}^\top \mathbf{y})$$

となり、線形性（スカラー倍の同伴性）が成立する。（証明終）

[問題へ戻る]



### 3-2. パラメータ線型モデルの表現（特徴写像）

#### 問 15 多項式特徴写像による線型表現

難易度：★ 1

1 次元の入力  $x$  に対し、特徴写像を  $\phi(x) = (1, x, x^2)^\top$  と定義する。パラメータベクトルを  $\theta = (\theta_0, \theta_1, \theta_2)^\top$  とする。

1. 内積によるモデル表現  $f(x) = \theta^\top \phi(x)$  を書き下せ。
2. このモデルは、パラメータ  $\theta$  に着目すると何次式か。また、入力  $x$  に着目すると何次式か答えよ。

[解答・解説へ]

#### 問 16 テキストデータへの適用（Bag-of-Words）

難易度：★ 0

語彙として「AI」「経営」「データ」の 3 語のみを考える。ある文書から抽出した頻度ベクトル（特徴写像）が  $\phi = (2, 0, 3)^\top$  であり、モデルの重みパラメータが  $\theta = (5, -2, 4)^\top$  のとき、この文書に対するスコア（内積）を計算せよ。

[解答・解説へ]

### 3-2. の解答・解説

【該当内容】第 3 回スライド 27～37「一般の線型モデル、特徴写像」【ねらい】「パラメータには線型（1 次式）だが、入力データに対しては非線型」という機械学習モデルの柔軟性を、多項式写像や Bag-of-Words などの具体例を通じて体感する。

#### 問 15 の解答・解説

1.

$$f(x) = \theta_0 \cdot 1 + \theta_1 \cdot x + \theta_2 \cdot x^2 = \theta_0 + \theta_1 x + \theta_2 x^2$$

2. パラメータ  $\theta$  に対しては 1 次式（線型）、入力  $x$  に対しては 2 次式（非線型）である。

[問題へ戻る]

#### 問 16 の解答・解説

スコアは内積  $\theta^\top \phi$  で計算される。

$$\theta^\top \phi = 5 \times 2 + (-2) \times 0 + 4 \times 3 = 10 + 0 + 12 = 22$$

[問題へ戻る]

### 3-3. 最小二乗法の行列表記と一階の条件（最重要）

#### 問 17 行列とベクトルによる目的関数の書き直し

難易度：★ 1

$n = 2$  個のデータがあり、それぞれの特徴ベクトルと正解ラベルが、

$$\phi(x_1) = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, y_1 = 4, \quad \phi(x_2) = \begin{pmatrix} 1 \\ 5 \end{pmatrix}, y_2 = 7$$

である。デザイン行列  $\Phi = \begin{pmatrix} \phi(x_1)^\top \\ \phi(x_2)^\top \end{pmatrix}$  およびラベルベクトル  $\mathbf{y} = (y_1, y_2)^\top$  を具体的に数字で書き下し、目的関数

$$L(\theta) = \frac{1}{2} \|\Phi\theta - \mathbf{y}\|^2$$

が個別の二乗誤差の和  $\frac{1}{2} \sum_{i=1}^2 (y_i - \theta^\top \phi(x_i))^2$  と完全に等しいことを展開して確かめよ。

[解答・解説へ]

### 問 18 一階の条件の行列導出

難易度：★ 2

行列微分の公式

$$\begin{aligned} \nabla_{\theta}(\mathbf{a}^\top \theta) &= \mathbf{a} \\ \nabla_{\theta}(\theta^\top \mathbf{A} \theta) &= 2\mathbf{A}\theta \quad (\mathbf{A} \text{ は対称行列}) \end{aligned}$$

を用いて、目的関数  $L(\theta) = \frac{1}{2}(\Phi\theta - \mathbf{y})^\top(\Phi\theta - \mathbf{y})$  の勾配  $\nabla_{\theta}L(\theta)$  を求め、一階の条件  $\nabla_{\theta}L(\theta) = \mathbf{0}$  から正規方程式

$$\Phi^\top \Phi \theta = \Phi^\top \mathbf{y}$$

を導出せよ。

[解答・解説へ]

### 3-3. の解答・解説

【該当内容】第 3 回スライド 38～44「線型モデルの最小二乗法、行列による表記」【ねらい】データの羅列をデザイン行列  $\Phi$  とラベルベクトル  $\mathbf{y}$  にまとめ、目的関数をベクトルのノルムとしてスッキリ表現するテクニックと、その微分プロセスを完全にマスターする。

#### 問 17 の解答・解説

デザイン行列  $\Phi$  とラベルベクトル  $\mathbf{y}$  は以下になる。

$$\Phi = \begin{pmatrix} 1 & 2 \\ 1 & 5 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 7 \end{pmatrix}$$

パラメータを  $\theta = (\theta_0, \theta_1)^\top$  とすると、

$$\Phi\theta - \mathbf{y} = \begin{pmatrix} 1 & 2 \\ 1 & 5 \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} - \begin{pmatrix} 4 \\ 7 \end{pmatrix} = \begin{pmatrix} \theta_0 + 2\theta_1 - 4 \\ \theta_0 + 5\theta_1 - 7 \end{pmatrix}$$

ベクトルの L2 ノルムの 2 乗は各成分の 2 乗和なので、

$$\frac{1}{2} \|\Phi\theta - \mathbf{y}\|^2 = \frac{1}{2} [(\theta_0 + 2\theta_1 - 4)^2 + (\theta_0 + 5\theta_1 - 7)^2]$$

これは各データの誤差二乗和  $\frac{1}{2} \sum_{i=1}^2 (\theta^\top \phi(x_i) - y_i)^2$  と完全に一致する。(証明終)

[問題へ戻る]

#### 問 18 の解答・解説

目的関数  $L(\theta)$  を展開する。内積はスカラーであり転置しても値が変わらないため、 $\mathbf{y}^\top \Phi\theta = (\mathbf{y}^\top \Phi\theta)^\top =$

$\theta^\top \Phi^\top \mathbf{y}$  が成り立ち、中央の項がまとめられる。

$$L(\theta) = \frac{1}{2} [\theta^\top \Phi^\top \Phi \theta - 2(\Phi^\top \mathbf{y})^\top \theta + \mathbf{y}^\top \mathbf{y}]$$

ここで、 $\mathbf{A} = \Phi^\top \Phi$  とおくと、これは対称行列である。行列微分の公式を適用して  $\theta$  で勾配を計算する。

$$\nabla_\theta L(\theta) = \frac{1}{2} [2\Phi^\top \Phi \theta - 2\Phi^\top \mathbf{y}] = \Phi^\top \Phi \theta - \Phi^\top \mathbf{y}$$

一階の条件  $\nabla_\theta L(\theta) = \mathbf{0}$  より、

$$\Phi^\top \Phi \theta - \Phi^\top \mathbf{y} = \mathbf{0} \quad \Rightarrow \quad \Phi^\top \Phi \theta = \Phi^\top \mathbf{y}$$

が導出された。(証明終)

[問題へ戻る]

### 3-4. 正則化 (Regularization)

#### 問 19 L2 ノルムの性質

難易度：★ 0

ベクトル  $\mathbf{w} = (3, -4)^\top$  の L2 ノルム  $\|\mathbf{w}\|$  を計算し、それが自身との内積の平方根  $\sqrt{\mathbf{w}^\top \mathbf{w}}$  と等しいことを示せ。

[解答・解説へ]

#### 問 20 L2 正則化付き目的関数の書き下し

難易度：★ 1

損失関数を二乗誤差、正則化項を L2 ノルムの 2 乗とし、正則化係数を  $\lambda = 0.01$  とする。 $n$  個のデータに対する L2 正則化付き経験リスク最小化の目的関数  $L_{\text{reg}}(\theta)$  の式をシグマ表記で書き下せ。

[解答・解説へ]

#### 問 21 行列による書き直しと一階の条件

難易度：★ 2

目的関数を  $L_{\text{reg}}(\theta) = \frac{1}{2} \|\Phi \theta - \mathbf{y}\|^2 + \frac{\lambda}{2} \|\theta\|^2$  とする。全体の勾配を  $\mathbf{0}$  と置く一階の条件から、最適解

$$\hat{\theta} = (\Phi^\top \Phi + \lambda \mathbf{I})^{-1} \Phi^\top \mathbf{y}$$

を導出せよ。なぜ単位行列  $\mathbf{I}$  が必要なのか説明せよ（ただし逆行列は存在すると仮定する）。

[解答・解説へ]

### 3-4. の解答・解説

【該当内容】第 3 回スライド 45~50「過適合の対策>正則化、L2 正則化」【ねらい】過学習を防ぐ L2 正則化 (Ridge) の目的関数について、代数表現と行列表現の一致を確かめ、単位行列  $\mathbf{I}$  が出現する理由を数式変形で完全に理解する。

#### 問 19 の解答・解説

L2 ノルムの計算：

$$\|\mathbf{w}\| = \sqrt{3^2 + (-4)^2} = \sqrt{9 + 16} = \sqrt{25} = 5$$

内積の平方根の計算：

$$\mathbf{w}^\top \mathbf{w} = 3 \times 3 + (-4) \times (-4) = 9 + 16 = 25 \quad \Rightarrow \quad \sqrt{\mathbf{w}^\top \mathbf{w}} = 5$$

よって  $\|\mathbf{w}\| = \sqrt{\mathbf{w}^\top \mathbf{w}} = 5$  となり、一致する。

[問題へ戻る]

#### 問 20 の解答・解説

経験誤差の平均と、パラメータの L2 ノルム平方に正則化係数を掛けたものを合算する。

$$L_{\text{reg}}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \theta^\top \phi(x_i))^2 + 0.01 \|\theta\|^2$$

[問題へ戻る]

#### 問 21 の解答・解説

$\|\theta\|^2 = \theta^\top \theta$  より、第 2 項の勾配は  $\nabla_{\theta} \left( \frac{\lambda}{2} \theta^\top \theta \right) = \lambda \theta$  である。これと二乗誤差項の勾配を合わせ、全体の勾配を一階の条件に従って  $\mathbf{0}$  と置く。

$$\nabla_{\theta} L_{\text{reg}} = \Phi^\top \Phi \theta - \Phi^\top \mathbf{y} + \lambda \theta = \mathbf{0}$$

ここで  $\theta$  でまとめる際、行列  $\Phi^\top \Phi$  とスカラー  $\lambda$  は直接足し算できない。そのため、 $\lambda \theta = \lambda \mathbf{I} \theta$  ( $\mathbf{I}$  は単位行列) と変形する。

$$(\Phi^\top \Phi + \lambda \mathbf{I}) \theta = \Phi^\top \mathbf{y}$$

両辺に左から逆行列を掛けることで、最適解が得られる。

$$\hat{\theta} = (\Phi^\top \Phi + \lambda \mathbf{I})^{-1} \Phi^\top \mathbf{y}$$

**【単位行列  $\mathbf{I}$  の必要性】** 行列 (サイズ  $d \times d$ ) とスカラー (単なる数値) は代数的に直接加算できないため、同じサイズで対角線上にスカラーを配置する単位行列  $\mathbf{I}$  を仲介させることで、正則化項を行列演算に統合している。

[問題へ戻る]

### 3-5. モデル選択 (交差検証)

#### 問 22 K-fold と LOOCV のインデックス計算

難易度：★ 0

1.  $n = 6$  個のデータを  $K = 3$  個のフォルダ

$$D_1 = \{1, 2\}, \quad D_2 = \{3, 4\}, \quad D_3 = \{5, 6\}$$

に分割する。第 2 イテレーション ( $D_2$  が検証用) において、訓練に使用されるデータのインデックスをすべて答えよ。

2. サンプルサイズが  $n = 100$  のデータに LOOCV (一箇抜き交差検証) を行う場合、モデルの学習は合計で何回実行されるか。

[解答・解説へ]

### 3-5. の解答・解説

【該当内容】第3回スライド51~70「モデル選択、交差検証」【ねらい】ハイパーパラメータ選択の手続きを、インデックス操作を通じて厳密に理解する。

#### 問22の解答・解説

1. 全体のデータ  $\{1, 2, 3, 4, 5, 6\}$  から検証用の  $D_2 = \{3, 4\}$  を除外した、 $\{1, 2, 5, 6\}$  が訓練用データとなる。
2. LOOCV はデータから1点だけを検証用として抜き出し、残りの  $n - 1$  点で訓練する作業をデータの個数分だけ繰り返す。したがって、実行回数は合計で **100 回** である。

[問題へ戻る]

## 【第4回】確率モデルと分位点回帰

### 4-1. 同時分布・条件付き分布・条件付き期待値

#### 問23 同時確率表からの条件付き分布と期待値

難易度：★1

離散確率変数  $X \in \{0, 1\}$  と  $Y \in \{1, 2, 3\}$  の同時確率  $P(X, Y)$  について、 $X = 0$  のとき、 $Y = 1, 2, 3$  となる確率はそれぞれ  $0.1, 0.2, 0.1$  である。

1.  $X = 0$  となる周辺確率（正規化定数） $P(X = 0)$  を求めよ。
2.  $X = 0$  という条件のもとでの  $Y$  の条件付き確率分布  $P(Y = y \mid X = 0)$  を求めよ。
3. 上記の分布を用いて、条件付き期待値  $\mathbb{E}[Y \mid X = 0]$  を計算せよ。

[解答・解説へ]

### 4-1. の解答・解説

【該当内容】第4回スライド5~18「基本知識>同時確率分布、条件付き確率」【ねらい】条件付き確率・条件付き期待値を、クロス集計表の計算から完全に理解する。

#### 問23の解答・解説

1. 周辺確率は、与えられた  $X = 0$  における  $Y$  のすべての確率の和である。

$$P(X = 0) = P(X = 0, Y = 1) + P(X = 0, Y = 2) + P(X = 0, Y = 3) = 0.1 + 0.2 + 0.1 = 0.4$$

2. 条件付き確率の定義  $P(Y = y \mid X = 0) = \frac{P(X=0, Y=y)}{P(X=0)}$  より、

$$P(Y = 1 \mid X = 0) = \frac{0.1}{0.4} = 0.25$$

$$P(Y = 2 \mid X = 0) = \frac{0.2}{0.4} = 0.50$$

$$P(Y = 3 \mid X = 0) = \frac{0.1}{0.4} = 0.25$$

3. 条件付き期待値は、求めた条件付き確率を用いた期待値計算である。

$$\begin{aligned}\mathbb{E}[Y \mid X = 0] &= 1 \times P(Y = 1 \mid X = 0) + 2 \times P(Y = 2 \mid X = 0) + 3 \times P(Y = 3 \mid X = 0) \\ &= 1 \times 0.25 + 2 \times 0.50 + 3 \times 0.25 \\ &= 0.25 + 1.0 + 0.75 = 2.0\end{aligned}$$

## 4-2. 分位点 (Quantile) と外れ値の影響

## 問 24 飛びのある分布の分位点とロバスト性

難易度：★ 1

1. データセット  $\{2, 3, 5, 7, 100\}$  の平均値と中央値を求めよ。
2. 外れ値の 100 が 1000 に化けたとする。このとき平均値と中央値はどう変化するか計算し、ピンボール損失 (中央値の場合は絶対値損失) が外れ値に対して持つ優位性を説明せよ。

[解答・解説へ]

## 問 25 ピンボール損失のグラフ描写の理解

難易度：★ 1

ピンボール損失関数

$$l_{\alpha}(y, y') = \begin{cases} (\alpha - 1)(y - y') & (y - y' < 0) \\ \alpha(y - y') & (y - y' \geq 0) \end{cases}$$

において、 $\alpha = 0.3$  とする。誤差  $e = y - y'$  が  $e = -2$  のときと  $e = 4$  のときの損失の値をそれぞれ計算し、グラフの形状を説明せよ。

[解答・解説へ]

## 4-2. の解答・解説

**【該当内容】** 第 4 回スライド 19~35「分位点回帰、ピンボール損失」**【ねらい】** 平均値が外れ値に引っ張られやすいのに対し、分位点 (中央値など) が頑健 (ロバスト) である理由を、実際のデータ操作を通じて数式ベースで理解する。

## 問 24 の解答・解説

1. 平均値の計算：

$$\frac{2 + 3 + 5 + 7 + 100}{5} = \frac{117}{5} = 23.4$$

中央値の計算：データを昇順に並べた中央の値なので、**5**。

2. 外れ値が 1000 になった場合の計算：

$$\text{新平均値} = \frac{2 + 3 + 5 + 7 + 1000}{5} = \frac{1017}{5} = 203.4$$

新中央値：順序関係は変わらないため、依然として **5**。

**【絶対値損失の優位性】** 二乗誤差に基づく「平均値」は外れ値の極端な大きさ (距離の 2 乗) に引っ張られるが、絶対値損失に基づく「中央値」は、各データ点が「自分より大きい小さいか (符号のみ)」しか評価しないため、どれほど巨大な外れ値に対しても結果が変化せず極めて頑健 (ロバスト) である。

[問題へ戻る]

## 問 25 の解答・解説

誤差  $e = y - y'$  を用いてそれぞれの場合を計算する。

1.  $e = -2 < 0$  のとき：

$$l_{0.3} = (0.3 - 1) \times (-2) = (-0.7) \times (-2) = 1.4$$

2.  $e = 4 \geq 0$  のとき：

$$l_{0.3} = 0.3 \times 4 = 1.2$$

【グラフの形状】誤差  $e = 0$ （予測値と正解ラベルが一致している点）を最下点（損失 0）とし、負の領域（予測過剰）では傾き  $-0.7$  の急な直線、正の領域（予測不足）では傾き  $0.3$  の緩やかな直線となる、非対称な V 字型の形状をとる。

[問題へ戻る]

## 【第 5 回】確率論的二値分類と非線型最適化

### 5-1. ロジスティック関数の微分と交差エントロピー

#### 問 26 シグモイド関数の微分証明

難易度：★ 2

ロジスティック関数（シグモイド関数） $\sigma(z) = \frac{1}{1+e^{-z}}$  について、

1. 商の微分公式を用いて  $\sigma'(z) = \sigma(z)(1 - \sigma(z))$  になることを証明せよ。
2. 合成関数の微分則を用いて  $\frac{d}{dz} \log \sigma(z) = 1 - \sigma(z)$  が成り立つことを示せ。

[解答・解説へ]

#### 問 27 交差エントロピーとチェインルールによる勾配導出

難易度：★ 2

交差エントロピー損失

$$l = -y \log \sigma(z) - (1 - y) \log(1 - \sigma(z)) \quad (\text{ただし } z = \theta^\top \phi(x))$$

について、チェインルール  $\nabla_\theta l = \frac{\partial l}{\partial z} \cdot \nabla_\theta z$  を用いて、勾配ベクトルが

$$\nabla_\theta l = (\sigma(z) - y) \phi(x)$$

となることを導出せよ。

[解答・解説へ]

### 5-1. の解答・解説

【該当内容】第 5 回スライド 50～89「確率論的二値分類、交差エントロピー、勾配の導出」【ねらい】天下りの与えられるシグモイド関数の微分公式を自力で完全に導出し、交差エントロピー損失のパラメータ微分（チェインルール）を実行して、アルゴリズムの動作を数式で裏付ける。

#### 問 26 の解答・解説

1. 商の微分公式  $\left(\frac{1}{g(z)}\right)' = -\frac{g'(z)}{(g(z))^2}$  を用いる。 $g(z) = 1 + e^{-z}$  とおくと、 $g'(z) = -e^{-z}$  である。

$$\sigma'(z) = -\frac{-e^{-z}}{(1 + e^{-z})^2} = \frac{e^{-z}}{(1 + e^{-z})^2} = \left(\frac{1}{1 + e^{-z}}\right) \left(\frac{e^{-z}}{1 + e^{-z}}\right)$$

ここで、右側の項の分子に  $1 - 1$  を補う。

$$\frac{e^{-z}}{1 + e^{-z}} = \frac{1 + e^{-z} - 1}{1 + e^{-z}} = \frac{1 + e^{-z}}{1 + e^{-z}} - \frac{1}{1 + e^{-z}} = 1 - \sigma(z)$$

よって、

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

となる。(証明終)

2. 合成関数の微分公式  $(\log f(z))' = \frac{f'(z)}{f(z)}$  と、(1) の証明結果を用いる。

$$\frac{d}{dz} \log \sigma(z) = \frac{\sigma'(z)}{\sigma(z)} = \frac{\sigma(z)(1 - \sigma(z))}{\sigma(z)} = 1 - \sigma(z)$$

となり、成立する。(証明終)

[問題へ戻る]

## 問 27 の解答・解説

対数尤度損失  $l$  を  $z$  について偏微分する。

$$\frac{\partial l}{\partial z} = -y \frac{d}{dz} (\log \sigma(z)) - (1 - y) \frac{d}{dz} (\log(1 - \sigma(z)))$$

第 1 項 of 微分は問 9 の (2) より  $1 - \sigma(z)$ 。第 2 項 of 微分は同様に、

$$\frac{d}{dz} \log(1 - \sigma(z)) = \frac{-\sigma'(z)}{1 - \sigma(z)} = \frac{-\sigma(z)(1 - \sigma(z))}{1 - \sigma(z)} = -\sigma(z)$$

これらを代入して整理する。

$$\begin{aligned} \frac{\partial l}{\partial z} &= -y(1 - \sigma(z)) - (1 - y)(-\sigma(z)) \\ &= -y + y\sigma(z) + \sigma(z) - y\sigma(z) \\ &= \sigma(z) - y \end{aligned}$$

次に、勾配  $\nabla_{\theta} z$  を計算する。 $z = \theta^{\top} \phi(x)$  はパラメータ  $\theta$  について線型であるため、

$$\nabla_{\theta} z = \phi(x)$$

チェインルールを適用して両者を掛け合わせる。

$$\nabla_{\theta} l = \frac{\partial l}{\partial z} \cdot \nabla_{\theta} z = (\sigma(z) - y)\phi(x)$$

なり、導出された。(証明終)

[問題へ戻る]