

第1回

手嶋毅志 (Takeshi Teshima)



ガイドンス

講義概要

講義名

経営学への応用を目指すAI入門

テーマ

人工知能の仕組みと応用，特に機械学習

経営学との関わり

授業のキーワード

機械学習，人工知能，大規模言語モデル，科学哲学，経営学

担当教員の自己紹介

手嶋 毅志 (Takeshi Teshima)

- 専門：機械学習
- 興味：因果的機械学習, 科学のための機械学習など
- 略歴
 - 2017年 東京大学経済学部 経営学科卒業 (学士)
 - 2022年 東京大学新領域にて博士号 (科学)
 - 企業でデータサイエンティストをしています
- 詳しくは <https://takeshi-teshima.info>



学習リソース

講義資料

下記のサイト上で配布します。自習等の参考にしてください（LETUSにもリンクあります）

講義資料

スライド中の図などを再現するソースコードは全て以下に置きます。

<https://takeshi-teshima-lecture-supplement.netlify.app>

Google Colab（無料）を用いて簡単に試すことができます。

LETUS「998654R 特殊講義 1」

講義名で見つけて、必ず自己登録してください。テストの実施に使います。

成績評価

出席

ありません

70%：講義内容の理解を確認する小テスト

ほぼ毎回出題する理解のための小テスト（クイズ）。LETUS上で実施してください

第15回（到達度評価）の講義開始時刻まで再提出可能（最大評点を採用します）

難易度は聞いて理解していれば正解できる程度。間違えたら要復習のサイン

30%：到達度評価・講義への高度な参加

到達度評価（30%満点），質問による加点（後述）

（質問による加点を，到達度評価の結果に加算して，合計30%までとする）

質問読み上げ

質問の一部は、次の講義の冒頭で読み上げて解説します

- 読み上げられた方には加点します（+それと同じ質問をしていた方にも）
- **LETUS**の「質問・フィードバック投稿フォーム」を通して提出されたものだけが加点の対象になります
- 読み上げ対象の質問は、原則、講義のある週の**火曜日23:59**に締め切ります
 - それ以降に届いたものは次回以降に取り上げるかもしれません



講義全体に関する注意事項

言語と講義形式

講義は全編にわたって日本語で行います。同期オンラインでの開講です。

講師への連絡方法

講義内容に関係しない質問（学務など）はメールにて送ってください（アドレスはシラバスに記載）。返答に時間がかかる場合もあるので、平均で2日間、最大で1週間程度の時間差を見込んでください。


講師からの連絡方法

LETUSのアナウンスメントを使用します

第0部 講義の概観

人工知能（Artificial Intelligence, AI）

人工知能， AI， という言葉は， 至るところに現れている



“AI”の得体の知れなさ

あまりにも広い分野で活躍しているAI。その正体とは？何でもできるのか？

至る所で
使われ始めている

なんでもできる
ように見える




このまま色々なことに
使っていいのか？

何ができて
何ができないのか？

“AI”の得体の知れなさ > その正体とは？


要素技術が、その時々に応用目的に応じて組み合わせられてAIが実現されている



【参考】 人工知能学会「AIマップβ 2.0（2023年5月版）」（<https://www.ai-gakkai.or.jp/aimap/>）を参考に大幅に加筆・改変したもの

“AI”の得体の知れなさ > その正体とは？


情報技術を使って知的な処理を行う成功事例は、大体AIと呼ばれてしまう



AIです



AIだ！



(反応がいいからAIと呼んでおこう……)

AIです



これもAI！



“AI”の得体の知れなさ > その正体とは？

- あまりにも広い分野で活躍しているAI。その正体とは？
 - 情報技術の（成功した）応用例が、あれもこれも「AI」と呼ばれている
- 何でもできるのか？
 - AIの名の下に”売り出されている”それぞれの要素技術が発展すると、それに伴ってできることが増える
 - 限界も、要素技術の仕組みや最高到達点から自ずと決まってくる

AIという一つの技術があちこちで活躍しているわけではない。

AIの名のもとに応用されている技術は多岐にわたる。

AIの要素技術を学ぶ



分野が多くてどう学んだらいいものか……

- この講義では、AIの裏側の要素技術を、なるべく全体的に学べるようにしたい
- ただ、たくさんの技術があるので、全てを筋道立てて学ぶのは難しい

講義の主題

この講義は「機械学習」の技術を軸として展開



機械学習

機械学習とは

知的な仕事をする能力をデータから自動的に獲得させる技術

■ 機械学習 (machine learning)


- 明示的にプログラミングすることなく、知識や規則性をデータから自動的に発見・獲得させる技術

■ “明示的にプログラミングすることなく”……？

- そもそもコンピューターは、ただの高性能な計算機
- プログラムの通りに四則演算・条件分岐などの処理をすることしかできない
- それでも、なんとか、人間が行うような知的な処理をさせたい（人工知能）

人工知能の略史


人工知能を作る試みは、過去何度かに渡って行われてきた



【補足】当然ながら、各時代において人類が一枚岩でこれらの試みを行ってきたわけではない。様々な研究者や研究機関が、多様なアプローチで試みてきたことを後世から見れば大まかにはこのような時代の趨勢があったと言えそうだ、という話である。

人工知能の略史

第1次AIブーム（推論・探索システムの時代）



1

1956年 ダートマス会議

- ▶ 「人工知能」という用語が初めて使われた

コンピューターがあるし
人工知能もできるのでは？

- ▶ 「推論と探索」の研究が進み、ルールが分かる特定の問題（迷路など）であれば解を提示できるシステムが開発された時代

1970年代 AI冬の時代へ


期待したほどではないな……

- ▶ ヒトより高速に情報処理できるモノとしてのAI
→ 解法が分かる問題ばかりではないことで限界を迎えて冬の時代へ

【補足】 ダートマス会議には、情報理論の考案者であるClaude Shannonや、組織論でも有名なHerbert Simonを含む、後のビッグネームたちが多数参加した。冬の時代の要因として、単純パーセプトロンの理論限界や、当時の計算機の性能の限界も挙げられる。

人工知能の略史

第2次AIブーム（知識と推論の時代）



2

1980年代 エキスパートシステムなどが開発

- ▶ 簡単な推論規則 + 膨大な知識の集合を使う
アプローチ

膨大な知識 + 推論規則によって人工知能ができそうかも！

- ▶ 「三段論法 ($A \Rightarrow B$ かつ $B \Rightarrow C$, ならば $A \Rightarrow C$)」などの推論規則と
「発熱があれば〇〇感染の確率が70%」などの知識を集めたもの
があれば、医師のように診断ができる？

1995年頃～ AI冬の時代へ


やっぱり無理そう

- ▶ ヒトより多くの知識を扱えるモノとしてのAI

→ 知識の表現・管理・更新の大変さで限界を迎えて冬の時代へ

人工知能の略史

第3次AIブーム（統計的機械学習の時代）



データ + 機械学習なら
AIができそうかも！

3

2010年代～ 統計的機械学習が発展

- ▶ 知識や規則を明示的にプログラミングせず、データから自動的に獲得させようとするアプローチ
- ▶ 時代の追い風：①インターネット時代によるデータ量の増加，②高性能な計算機の普及

～現在

- ▶ 人でも扱えない複雑な規則性をデータから学習するモノとしてのAI
→冬の時代に突入することなく，現在に至る成功を収めている


4

第4次ブーム（基盤モデルの時代）

【補足】第3次ブームが第1～2次と一線を画して成功している背景には，インターネットの普及によりデータ量やコンピューターの性能が大幅に上がっていることが挙げられる。さらに，実用的なアルゴリズムの開発で，第1～2次とは異なり深層ニューラルネットの学習が成功を収めたことも大きい。


講義全体の構成

第Ⅰ部



機械学習の仕組み

第Ⅱ部



応用領域の案内


第Ⅲ部



発展編

講義全体の構成＞第Ⅰ部

「機械学習の基本の考え方が分かった」というところまで行く



機械学習の仕組み

なんか学習っていうの
やってんでしょ？



データを食わせるって何？




機械学習の
仕組みが分かる



学習の原理や基本概念に
キャッチアップ

講義全体の構成＞第Ⅱ部

データの種別別に「機械学習」の応用を俯瞰する



応用領域の案内

表形式データ,
画像データ,
テキストデータ, ……



AIはどれをどう扱えるの？



データの種類と性質,
コンピューターの中で
どう扱われるかが分かる



応用分野ごとの
「常識」レベルの知識に
キャッチアップ

講義全体の構成＞第III部

原理と応用を知った上で、その使い方や、限界と今後について考える



発展編

限界と未来

?

受講の目標到達地点

次の3つを得ることを目指す

1) 情報収集の解像度

「AI」という単語が使われている記事を読むとき、裏側の仕組みを知識に基づいて推測できる




2) 原理と限界の考察力

AIの現時点での適用限界・課題と未来について考えられるようになる



3) 道具的価値の実現

いざ自分のためにAIを使うとき、「仕組み上、この使い方で合っているはずだ」と自信を持って使えるようになる



はじまり

AIの基礎と応用の世界へ



この講義で必要となる予備知識

予備知識＞プログラミング

機械学習の面白さに触れるには、自分で動かしてみることが一番

- まずは、自分でプログラムを書かなくても、実行ボタンを押して結果が出力されるのを眺めるところから
- この講義では、実際に動かせるプログラムを資料として提供しています
- この講義ではプログラミング不要
 - ただし、学んでおくと大きなアドバンテージに

予備知識＞プログラミング

講義の補助資料サイトにてソースコードを公開しています



■ <https://takeshi-teshima-lecture-supplement.netlify.app/introduction-to-ai>

-  のボタンを押すと、Google Colab上で内容を開くことができ、そのまま実行できます

Supplement Material

講義資料

[講義のスライドはこちら](#)（閲覧のみ）


ソースコード一覧

説明	ファイル	Colab
	01_01_intro_handson.ipynb	
	01_02_simple_linear_ols_regression.ipynb	

予備知識＞プログラミング＞Google Colab

Googleが提供している、クラウド上のPython実行環境

- 基本無料で使える




- 基本の使い方のサポートはできないので、各自で調べながら使ってください 🙏
- ※iPadやiPhoneだと、画面サイズなどの問題で上手く使えない可能性があります

演習課題



(番号) _intro_handson.ipynbを開いて実行してみてください

- 1) <https://takeshi-teshima-lecture-supplement.netlify.app/introduction-to-ai> にアクセス
- 2) 「01_01_intro_handson.ipynb」の  Open in Colab ボタンを押す
- 3) ノートブックが開いたら、ツールバーの「ランタイム>すべてのセルを実行」を押すか、（上から順に）一個一個のセルの  ボタンを押していくと実行できる

基本知識＞数学

大学1年生レベルの数学は基本知識として仮定します（触れた程度で十分）

■ 微分・積分

- $\log(x)$ の微分, e^x の微分, 偏微分など

■ 線型代数

- ベクトルの内積, 行列の積, 逆行列など

■ 確率・統計

- 期待値, 独立同分布 (i.i.d.), 条件付き確率, 正規分布など

■ 最適化

- 一階の条件など

基本知識の確認＞確率変数

確率的に値が決まる変数を**確率変数 (random variable)** という

- 「サイコロの出目」のように確率的に決まる値を確率変数という



X



3

x

- 確率変数の値には確率が割り当てられている
 - 完全な6面サイコロの場合

x	1	2	...	6
確率	$\frac{1}{6}$	$\frac{1}{6}$	...	$\frac{1}{6}$

【記号】 確率変数は大文字のアルファベットで表すことが多い： $X, Y, Z, \dots$ ，確率変数の値は実現値といい，小文字で表すことが多い： $x, y, z, \dots$

【補足】 確率変数とは何か？実現値とは何か？ということを（数学的に）スッキリ整理したいという人には，いちど測度論的確率論を学んでしまうことを勧める。

基本知識の確認＞確率分布

確率変数が「ある範囲に値を取る」確率のことを確率分布という

- ある範囲に値をとる確率 $\mathbb{P}(X \in A)$ （例）完全な6面サイコロの場合

$$\mathbb{P}(X \in \{1,2,3\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}, \quad \mathbb{P}(X \in \{3,6\}) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3} \text{ など}$$

- **確率分布（probability distribution）**

- 考えられる集合 A のそれぞれに対して、 X の値が A に入る確率を調べたもの

A	$\{\}$	$\{1\} \cdots \{6\}$	$\{1,2\} \cdots \{5,6\}$	...	$\{1,\dots,6\}$
$\mathbb{P}(X \in A)$	0	$\frac{1}{6} \cdots \frac{1}{6}$	$\frac{1}{3} \cdots \frac{1}{3}$		1

【補足】 正確に言えば、 X の確率分布とは、 $\mu(A) := \mathbb{P}(X \in A)$ で定義される関数 μ のこと（ここで A は、 X が値をとる空間の中で考えられるあらゆる部分集合）。

基本知識の確認＞確率分布（離散型と連続型）

確率変数・確率分布には、離散型のものと連続型のものがある


- 離散型確率変数：確率変数 X が飛び飛びの値をとる。確率質量関数で定義。
- 連続型確率変数：確率変数 X が連続的に値をとる。確率密度関数で定義。

確率質量関数 $p(x)$

x	x_1	x_2	$\cdots$	x_n
$p(x)$	p_1	p_2	$\cdots$	p_n

例) サイコロの出目の分布

確率密度関数 $p(x)$



例) ルーレットの値, 正規分布

【補足】 離散型でも連続型でもない分布も沢山存在する。

【用語】 確率質量関数 (probability mass function, p.m.f.) は、確率表 (probability table) や確率関数 (probability function) と呼ぶ。確率密度関数は英語では probability density function (p.d.f.)。確率質量関数や確率密度関数のことを、確率分布と同一視して単に「分布」と呼ぶことも多い。

基本知識の確認 > 確率分布（離散型と連続型） > 基本性質

確率質量関数（離散型）

確率密度関数（連続型）

0以上かつ
総和は1

$$p(x) \geq 0$$

$$p(x) \geq 0$$

$$\sum_x p(x) = 1$$

$$\int p(x)dx = 1$$

確率分布
 $\mathbb{P}(X \in A)$

$$\sum_{x \in A} p(x)$$

範囲内の確率の総和

$$\int_A p(x)dx$$

範囲内の確率密度の累積

基本知識の確認＞期待値

期待値は出現確率による重み付き平均

■ **確率変数 X の期待値** (expectation) $\mathbb{E}[X]$ は

- X の全ての値を, 出現確率 $p(x)$ を重みとして, 重み付き平均したもの

$$\mathbb{E}[X] := \begin{cases} \sum_x x \cdot p(x) & (\text{離散型の場合は和で定義}) \\ \int x \cdot p(x) dx & (\text{連続型の場合は積分で定義}) \end{cases}$$

■ 一般には, x の関数 f をかけた, **$f(X)$ の期待値** $\mathbb{E}[f(X)]$ は

- X の全ての値を, f に代入して, 出現確率 $p(x)$ で重み付き平均したもの

$$\mathbb{E}[f(X)] := \begin{cases} \sum_x f(x)p(x) & (\text{離散型の場合}) \\ \int f(x)p(x)dx & (\text{連続型の場合}) \end{cases}$$

【記号】 $:=$ は, 左辺を右辺によって定義することを表す記号。 【補足】 慣れてきたら, どちらも積分だと思って扱うほうが見通しがよくなる。

基本知識の確認＞数学＞ギリシア文字

ラテン文字（ABC……）とあわせて数式で使われます

- α, A アルファ β, B ベータ γ, Γ ガンマ 特に深い意味がないときに多い
- δ, Δ デルタ ϵ, E イプシロン 差分や微少量を表すときに多い
- ϕ, φ, Φ ファイ ψ, Ψ プサイ 関数やパラメーターを表すときに多い
- θ, Θ シータ η, H イータ パラメーターを表すときに多い
- λ, Λ ラムダ ρ, P ロー 係数などに使われやすい
- σ, Σ シグマ 頭文字がSのものを表すときに多い


基本知識の確認＞数学＞ギリシア文字

ラテン文字（ABC……）とあわせて数式で使われます

- μ, M ミュー 平均を表すことが多い
- τ, T タウ 時間を表すことが多い
- ν, N ニュー κ, K カッパ χ, X カイ これといって決まった使い方はない
- ξ, Ξ グザイ ζ, Z ゼータ ローマ文字でいう x で変数を表すときに多い
- π, Π パイ 円周率で使う． Π は何らかの積を表すために使われがち
- ω, Ω オメガ 全体集合・大きな集合を表すのに使われがち

予備知識＞数学の難易度

この講義での数学の難易度の上がりかた



第I部 機械学習の仕組み

第Ⅰ部で扱うタスク（知的な仕事）の類型

第Ⅰ部では、最も基本的な、予測系タスクのための機械学習を学ぶ



■ ここでいうタスクとは仕事のこと

- 人が行うような知的なタスクをコンピューターに肩代わりさせたい

【補足】画像の一部は、人工知能学会「AIマップβ2.0（2023年5月版）」（<https://www.ai-gakkai.or.jp/aimap/>）から抜粋・改変したもの。一部の文献では、上に挙げたような「データの背後の規則性を発見したり、それを利用して分類などの行動を取ったりする自動化された処理」はパターン認識と総称される

タスク（知的な仕事）の種類

コンピューターで実行できると嬉しい知的なタスクには様々な種類がある

予測系タスク



分析・発見系タスク



生成系タスク




推定系タスク




行動・制御系タスク



合意形成タスク



推薦・検索系タスク



他にもまだ色々な
タスクがある


【補足】画像の一部は、人工知能学会「AIマップβ2.0（2023年5月版）」（<https://www.ai-gakkai.or.jp/aimap/>）から抜粋・改変したもの。一部の文献では、上に挙げたような「データの背後の規則性を発見したり、それを利用して分類などの行動を取ったりする自動化された処理」はパターン認識と総称される

ロードマップ

第I部

予測系タスクの定式化

経験リスク最小化



予測系タスク

このパートで学ぶこと




以下の内容を，以下の順番で学びます

- まずは，予測系タスクの基本的な考え方
- 続いて，教師付き学習という方法論
- そして，簡単な具体例として線型最小二乗回帰

コンピューターで実現できたら嬉しいタスク


迷惑メールのフィルタリング


“Re:私の遺産を受け取っていた…”


“Re:先日はお越しいただき…”


“日程調整について…”

自動で振り分ける




コンピューターで実現できたら嬉しいタスク

手書き文字の読み取り



手書きした文字を撮影して
画像データとして保存




コンピューターで扱える
テキストや数値に変換

0, 0, 4, 1
0, 2, 3, 5

コンピューターで実現できたら嬉しいタスク

録音した音声の文字起こし



予測系タスク (Prediction task)

これらは抽象化すると「入力 x に対して正しい y を出力する」タスク

- 予測系タスク (prediction task) という




予測系タスク＞例

以下のようなタスクは予測系タスクの例

- 音声の文字起こし（入力：音声の波形を数値化したもの，出力：英単語1つ）



- 迷惑メールのフィルタリング（入力：テキスト，出力： $\{\bigcirc, \times\}$ どちらか）



基本知識の確認＞関数

「入力を受け取って、何か計算して、出力を返す、一定の処理」を関数という

- 入力 x を受け取って、 x から計算した何らかの値を出力するものが関数



- 例) 入力を2乗して出力する関数 $f(x) = x^2$



【細かい補足】「関数」は、数学では出力が数であるような写像を指すが、プログラミング等では入力を受け取って出力を返すような処理の固まりを指す。なお、出力を「返す (return)」というのはプログラミング系の用語。

予測系タスク

コンピューターで予測系タスクを解きたい

■ 予測系タスクを解くとはつまり……

- コンピューターにできる四則演算や条件分岐などの計算で表せる関数，かつ
- 色々な x を入力すると，それに対応して丁度正しい y が出てくる関数を作ること
とと言い換えられる



四則演算や条件分岐など
コンピューターにできる計算

予測系タスク＞用語

入力は**特徴量**，予測に使う関数は**予測器**，予測したい変数は**ラベル**と総称



【細かい補足】 予測というと未来の出来事に対する予言のような表現だが，それ以外の場合にも慣習的に「予測」という．特徴量・予測器・ラベルは，それぞれ分野や文脈によって様々な名前と呼ばれる．特定の状況でのみ使われる用語も多く，例えば「クラス」は，分類問題の場合におけるラベルの呼び名である．

【特徴量の別名】 予測変数 (predictor variable)，説明変数 (explanatory variable)，独立変数 (independent variable)，共変量 (covariate)，パターン (pattern)，

【予測器の別名】 回帰関数 (regression function)，分類器 (classifier)，識別器 (discriminator)，識別関数 (discriminant function)，判別関数 (discriminant function)

【ラベルの別名】 目標変数 (target variable)，目的変数 (objective variable)，応答変数 (response variable)，結果変数 (outcome variable)，被説明変数 (explained variable)，従属変数 (dependent variable)，クラス (class)，カテゴリー (category)


予測系タスク＞用語

ラベルの種類によって呼び分けられている

回帰タスク (regression task)

量的なラベル（正の実数など）を予測するタスク


- 例）動物の画像から体重を予測



分類タスク (classification task)（識別／判別／パターン認識タスクともいう）

質的なラベル（ $\{1, 2, \dots, C\}$ など）を予測するタスク

- 例）動物の画像を「犬/犬以外」に分類
- 分類ラベルはクラスやカテゴリーともよぶ




【補足】上記の区分でははっきり分けられない予測系タスクもある（例：ラベルが順序尺度や、グラフ構造や、画像や、文字列の場合など）。

予測系タスク＞例

ワインの化学的な計測データから、ブドウ品種を当てたい

- 特徴量：アルコール濃度や色相などの13個の数値
- ラベル：葡萄の品種名（Barolo, Barbera, Grignolino）



Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue		class
13.64	3.10	116	...	3.03	0.96	→	Barolo
14.21	4.04	111	...	2.65	0.87	→	Barolo
12.93	2.81	96	...	0.50	0.77	→	Barbera

【参考】 Forina, M., Armanino, C., Castino, M., Ubigli, M., 1986. Multivariate data analysis as a discriminating method of the origin of wines. VITIS - Journal of Grapevine Research 25, 189–189. <https://doi.org/10.5073/vitis.1986.25.189-201>


予測系タスク＞例

このタスクの場合の特徴量は，13次元のベクトル

- データを分析するとき，大体的場合は特徴量は1つではなく複数の数値からなるので，1つ1つのデータ点は数が幾つか並んだものになる




計測



アルコール度数：13.64
リンゴ酸：3.10
マグネシウム：116
⋮
フラボノイド：3.03
色：0.96


並べる


$$\begin{bmatrix} 13.64 \\ 3.10 \\ 116 \\ \vdots \\ 3.03 \\ 0.96 \end{bmatrix} \left. \vphantom{\begin{bmatrix} 13.64 \\ 3.10 \\ 116 \\ \vdots \\ 3.03 \\ 0.96 \end{bmatrix}} \right\} \text{13次元ベクトル}$$

- このように数値を並べたものをベクトルと呼ぶ． d 個の数が並んだベクトルは d 次元ベクトルという．

予測系タスク > 予測器


予測器 = 正しいラベル番号を出力できる（できそうな）計算式を作りたい



- ラベル番号は予め「Baroloは0, Barberaは1, Grignolinoは-1」などと決めておく
- 13個の数値を代入すると正しい品種番号が出てくる計算式を作れという問題

予測系タスク > 予測器の一例

例えばこんな関数も予測器



- $f(\mathbf{x}) = \text{sign}(3x_1 - x_2x_3 + x_3^3)$ (正なら1, 負なら-1, 零なら0)
- これでも立派な予測器
 - ただし, 適当に思いついた数式を書いただけなので全然当たらない

予測系タスク > よく当たる予測器を作るには



「良い予測器」の数式を思いつくのは至難のわざ

- エキスパートでも，アルコール濃度や色相などの数値から，どういう数式を立てれば正しい品種を当てられるかを考えることは流石に困難だろう
- 多くの予測タスクでこの状況になる
 - 人間なら感覚的に上手くできるタスクも，いざコンピューターでできる計算に落とし込もうとすると，どうすればいいか分からない

予測系タスク > よく当たる予測器を作るには



ここまでのスライドの中に、使えそうなものがあった

- 正しい入出力をペアにした過去の事例データは収集できる

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- ここから特徴量とラベルの関係について推測できれば、予測器を作れるかも

予測系タスク > 教師付き学習 (supervised learning)

正しい入出力をペアにした**ラベル付きデータ**から予測器を作る

- ラベル付きデータ $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$: 特徴量 x と正解ラベル y のペアを沢山集めたもの

例) ブドウ品種分類

特徴量: ワインの化学計測値13個

ラベル: 葡萄の品種名

データセット:

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

例) スпамメールを分類

特徴量: メールの中文字列

ラベル: spam (1) or not (0)

データセット:

(“Re:私の遺産を受け取って...”, 1)
(“Re:先日はお越しいただき...”, 0)
(“日程調整について...”, 0)
(“はじめまして...”, 1)

例) 手書き数字認識

特徴量: 画像 (28 × 28個の画素値)

ラベル: 0~9の整数値

データセット:

(, 0) (, 2) (, 0)
(, 0) (, 3) (, 4)
(, 1) (, 5)

【用語】ラベル付きデータ (labeled data) は、別名「教師データ」ともいう (一般に「学習データ」「訓練データ」とも)。データに基づいて望ましい予測器を作ることを「学習」という。【補足】入力 (= テストの問題) と、正しい出力 (= テストの正解) を教えるので、あたかも教師が付いているかのようだという比喻で「教師付き」という。

予測系タスク > 教師付き学習 > 人力では難しい

データの助けがあったとしても、人手で高度な計算式を思いつくことは難しい

- 予測器を思いつくために過去のデータを眺める

→ アルコール濃度が13.00以上，色相も0.85以上ならBarolo？

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- データ量は何万件になることも．13次元もある特徴量を全て考慮するのも困難.
 - 数百万件のデータ，数百次元の特徴量という応用もちらほらある．

予測系タスク＞データから予測器を作るには



データは集めた。さあ、ここからどうやって予測器を作るか？

- ラベル付きデータを沢山集めた。これは上手く使えば役に立つはず

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- ここから以下を説明
 - どうやって望ましい予測器を手に入れるか？
 - 望ましい予測器とは？

予測系タスクのための学習

予測系タスクの学習＞データから予測器を作るには



データは集めた。さあ、ここからどうやって予測器を作るか？


- ラベル付きデータを沢山集めた。これは上手く使えば役に立つはず

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- ここから以下を説明
 - どうやって望ましい予測器を手に入れるか？
 - 望ましい予測器とは？

予測系タスクの学習＞用語

- データセット (dataset) ・ 標本 (sample)
 - 収集された「ひとまとまりのデータ全体」のこと
 - そこに含まれる一つ一つのデータのことは、データ点 (data point) や事例 (instance, example) という




【補足】単に「データ」といった場合は、データセットを指すこともあれば、データ点を指すこともある。

予測系タスクの学習＞用語

学習（learning）・訓練（training）

- 手持ちのデータセットから予測器などを作ることを**学習**あるいは**訓練**という
- このとき使うデータセットは，訓練標本（training sample）・訓練データ（training data）・学習データなどという




【用語】 上記の通り，日本語では学習データという場合があるが，英語では普通「learning dataset」とは言わない．日本語でも英語でも「学習標本（learning sample）」とは言わない．

予測系タスクの学習 > ここから1次元入力の場合で説明




具体的な説明をするために、まずは単回帰と呼ばれるケースで説明していく

- 特徴量が1次元の場合の回帰を単回帰という。



- この場合、一つ一つの予測器は次のように曲線のグラフで図示できる



【注意】 当たり前だが、実用上は、特徴量が1次元ということはほとんどない。

予測系タスクの学習 > 予測器とする関数の候補



関数を作るといっても、何から始めればいい？

- 思いつくかぎり色々な式を考えて行っても埒が開かなそう

$$f(x) = x^2 + 2x + 10$$

$$f(x) = x \log x$$

$$f(x) = \frac{1}{1 + x^2}$$




$$f(x) = e^{\cos x}$$

モデルとパラメーター＞例

まず、調整可能な**パラメーター**のついた関数（モデルという）を用意する

■ 例：100次多項式 $f_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_{100} x^{100}$

- 以下は全て100次多項式のグラフだが、異なる $\theta_0, \dots, \theta_{100}$ の値に対するもの



■ パラメーターとは、上の θ のように調整可能で、値を変えると関数が変化する変数

【実験ソースコード】 [番号] _model_introduction.ipynb

【補足】 モデルにも色々な種類があり、上のように有限個のパラメーターだけを持つモデルは「パラメトリックモデル」という。詳しくは後述。

モデルとパラメーター

一般には、予測器の候補を集めた関数の集合をモデルという

■ モデル（モデルクラス）

$$\mathcal{M} := \{f_{\theta} \mid \theta \in \Theta\}$$

- 候補となる予測器の集合（関数を集めた集合）
- θ を決めると関数 f_{θ} が1つ定まるので、調整可能なパラメーター θ が付いた関数「 f_{θ} 」と解釈することもできる

■ 例)

- r 次多項式モデル，決定木モデル，ニューラルネットワークモデル，……

【用語】主に統計的機械学習の理論分野では、1個1個のモデルのことを仮説（hypothesis），モデル集合のことを仮説クラス（hypothesis class）や仮説集合（hypothesis set）と呼ぶこともある。また、モデルクラスから選んだ1個の関数のこともモデルということがある。

予測系タスクの学習＞候補の中で望ましい予測器






モデルのパラメーターを調整して，色々な関数を表現できる

- モデルのパラメーターをうまく調整することにより，色々な予測器を作ることができそうだ。
- どんな予測器にすればよいか分かれば，それに合うパラメーターを探索すれば良さそう。
- では，パラメーターの値をいくらにすればよいのか？

予測系タスクの学習＞望ましい予測器とは

手元のデータで正しい出力をできる関数は無数に考えられる

- 6個のラベル付きデータが手元に得られたとする。
- 次の3つの予測器はどれも、手元にあるデータに対して正しく予測を出せる



- 3つのうち、どれが良いか？


予測系タスクの学習＞望ましい予測器とは

予測器の良さは、未知のデータに対する性能で考える


■ 良い予測器とは、**汎化性能（generalization performance）**が高い予測器

- 手元のデータのみならず、**初見の入力でも予測がよく当たる**ということ


■ 手元のデータで正しいラベルを出力できるだけではダメ



↑
大きく外れた



↑
当たった



↑
少し外れた

予測系タスクの学習＞何が入力されるかは分からない



何が入力されるか分からないのに、予測を外すなというのは、流石に無理

- 後出しだからなんとでも言える？その通り.
- 実際、これから渡される未知の入力について我々は何も知らない
 - ✗ あらゆる入力で正確な予測を目指す
- そこで、次善策として、次を目指すことにする.

○ 未知のデータが色々と入力される中で、

平均的には正確な予測を目指す

重要な考え方

データは、背後にある生成分布からランダムに出てくると考える

- データは確率変数であり、背後にある生成分布からサンプリングされる



- そして、これからサンプリングされる未知のデータに対して、平均的に良い性能を目指す = 期待予測誤差が小さい予測器を作ることを目指す

$$\mathbb{E}_{X,Y} [\text{予測誤差}]$$

【補足】 多くの場合、図のような有限母集団からのサンプリングではなく、無限にサンプルを取れることを仮定する。細かいが、上をさらに正確に言えば「データは確率変数の実現値である」と仮定する。なお、生成分布そのものは未知でよいし、具体的な分布族も分からないものとする。

損失関数

予測誤差を定義するために、まずは損失関数を選ぶ

- 予測誤差の定義として用いる関数を**損失関数 (loss function)** という

$$\ell(y, y')$$

- 正解ラベルが y のデータで、予測器の出した予測が y' だった場合の誤差評価値
- 分析者自身が、何を誤差の定量的な指標としたいか考えて選ぶ

- 例

- **二乗損失関数** : $\ell(y, y') = (y - y')^2$ (回帰タスクでの定番)
- **0/1-損失** : $\ell_{0/1}(y, y') = \mathbf{1}\{y \neq y'\}$ (分類タスクでの定番)

リスク関数

予測器 f の良し悪しをこれから現れるデータに対する期待損失で定義する

- リスク関数 (risk) : 損失関数の期待値 (期待損失ともいう)

$$R(f) := \mathbb{E} [\ell(Y, f(X))] = \int \ell(y, f(x)) p(x, y) dx dy$$

- 例) 損失関数として二乗損失を選んだ場合

$$R(f) := \mathbb{E} [(Y - f(X))^2] = \int (y - f(x))^2 p(x, y) dx dy$$

予測系タスクの学習 > 統計的学習におけるゴール

モデルのパラメーターを調節し、リスクの値が小さい予測器を作りたい

$$R(f_{\theta}) := \mathbb{E} [\ell(Y, f_{\theta}(X))] \rightarrow \text{小さくしたい}$$

- リスクは「予測の外れ度合いの指標」なので、これを小さくするようにモデルのパラメーター θ を調節したい

予測系タスクの学習 > ゴール設定の工夫



期待値で誤差を測ると決めたことによって、何が変わったか？

- あらゆる入力で完璧な予測を出すことは諦めた
- 損失の期待値
 - 出現確率が高い入力 → 予測を外すと期待値に大きく影響
 - 出現確率が低い入力 → 多少おろそかにしても影響は軽微（重みが小さい）
- 全てを完璧に打ち返せなくてもいいので、総じて平均的には高性能になるように頑張ろうという現実的な目標になった

予測系タスクの学習 > ゴール設定の落とし穴



リスク関数を最小化すればいいのね！

- 落とし穴：データ (X, Y) の生成分布 $p(x, y)$ は未知

$$R(f) := \int \ell(y, f(x)) \underset{\substack{\uparrow \\ \text{未知}}}{p(x, y)} dx dy$$

- よって、 $R(f_\theta)$ が小さくなるようにパラメーターを探すどころか、1つの予測器 f_θ に対する $R(f_\theta)$ の値を求めることすらできない
- 「 $R(f_\theta)$ が小さくなるようにパラメーター θ を調節」はあくまで仮想的な目標であり、そのまま実現はできない

予測系タスクの学習 > ゴール設定の落とし穴の回避



ではどうすればよいか？ 期待値を，標本平均で近似しよう！

- 手持ちのデータが一定の条件を満たすならば，データ量が増えれば標本平均は期待値の良い近似であることが期待できる（cf. 大数の法則や中心極限定理）

$$\frac{1}{n} \sum_{i=1}^n X_i \quad \rightsquigarrow \quad \mathbb{E}[X]$$

標本平均 期待値

- そこで，手持ちのデータを使って， $R(f)$ を標本近似することにする．

予測系タスクの学習＞データに関する仮定

データに関する仮定

- **仮定**：訓練データは、テストデータと同じ分布から取ったIIDサンプル

$$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p$$

- ここで、 p はデータの生成分布（手持ちのデータとテストデータで共通）
-
- この仮定は何を意味するか？
 - 手持ちのデータで、リスク関数を近似することを正当化するための仮定

予測系タスクの学習 > リスクの標本近似

リスク $R(f)$ を手持ちの標本で近似する

■ リスク

$$R(f) := \mathbb{E} [\ell(Y, f(X))]$$

……期待値
(近似したい対象)

■ 経験リスク (empirical risk)

$$\hat{R}(f) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i))$$

……標本平均

【補足】 区別のために、リスクのことを期待リスクや母集団リスク (population risk) ということも稀にある (正式には単にリスクと呼ぶ)。特に断らなければ「期待」と言わなくてもリスクは損失の期待値のことを指す。

予測系タスクの学習 > 経験リスク最小化

経験リスクならデータから計算できるので、これをリスクの代わりに最小化

■ 経験リスク最小化 (empirical risk minimization, ERM)

- 経験リスクが最小になるようにパラメーターを決めるという手法

$$\hat{R}(f_{\theta}) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f_{\theta}(x_i)) \rightarrow \text{最小化}$$

- これは「教師付き学習」の基本的な型の一つ

これまでのあらすじ

- 予測器を作りたい（特徴量を代入するとラベルの予測値が出てくる関数）



- モデル f_{θ} を選び、損失関数 ℓ を決め、期待損失が小さいパラメーター θ を探す

$$R(f_{\theta}) := \mathbb{E} [\ell(Y, f_{\theta}(X))] \leftarrow \text{計算不可能だが小さくしたい}$$

- 現実的には、損失のサンプル平均の最小化なら実行できることを紹介

$$L(\theta) := \hat{R}(f_{\theta}) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f_{\theta}(x_i)) \rightarrow \text{Minimize}$$

- 具体例は次のセクション