

第4回

手嶋毅志 (Takeshi Teshima)

質問と回答

加対象の質問

今回、多項式モデルや三角多項式モデルなど、様々な特徴写像を挙げられましたが、それらをどう使い分けるかについてや、どのモデルが汎用性が高いかについて、教えてください。

データ（データ分布）の性質を考えて選びます。究極の意味で汎用的なものはありませんが（今回話す「学習の哲学」が関係します）、よく使われるものがあります。選択肢として持っておくと良いのは、

- ・ テーブルデータ → 多変数の多項式（交互作用項）：変数間の相乗効果がある場合
- ・ テーブルデータ → 離散化, 対数, B-Splines：金額は対数変換しておくなど
- ・ 周期データ（時系列） → 三角多項式：季節性や振動など、繰り返しのある場合
- ・ 画像など → HOG/Gaborなどの特徴や, 事前学習済みモデルの「ベクトル埋め込み」

加対象の質問

L2正則化の解説で、パラメーターの絶対値が大きくなるのを防ぐことで過学習を抑えるというお話がありました。逆に、特定のパラメーターを完全に0にして、不要な特徴量を削る（変数選択をする）ような正則化の手法もあるのでしょうか？

すごい質問ですね。はい、あります！

例えばLasso（ラッソ）と呼ばれる正則化があり、それはパラメーターを小さくするだけではなく「0になりやすくする」効果を持っています（スパース性を誘導する、と言います）

この講義でも、時間があれば入れたかったトピックの一つです。予測をよくするためのみならず、データを理解する「探索的データ分析」のために活用されています。

質問（続き）

変数選択タスクは、多数ある特徴量の中から重要なものだけを選択するタスクです。

不要な特徴量を削ると何が良いか？

- ・ 解釈性のために有用：どの特徴量が選択されたかに興味がある場合がある
- ・ 高速化のために有用：場合によっては学習や推論の時間の削減を期待できる
- ・ コスト削減に有用：データ取得時に必要な特徴量だけ用意すればよいことになる

古くから色々な方法が提案されていますが、特殊な正則化項（スパース性を導入する正則化項）を用いて教師付き学習をすることによる変数選択はその一つです。予測タスクのための学習を行うことで、結果的に変数選択をできるという手法、というわけです。

講義から外したスライドを使って説明します。

ℓ^0 ノルム正則化による変数選択（理想）

非ゼロ成分の個数 $\|\theta\|_0$ を用いて正則化する

$$\text{Min}_{\theta \in \Theta} \{L(\theta) + \lambda \|\theta\|_0\}$$

$$\|\theta\|_0 := \sum_{j=1}^d \mathbf{1}\{\theta_j \neq 0\}$$

■ 問題点

- 現実的な時間で実行可能な、よい最適化手法がない
（正確には、最悪の場合の計算時間が

ℓ^1 ノルム正則化 (Lasso)

$$\min_{\theta \in \Theta} \{L(\theta) + \lambda \|\theta\|_1\}$$

訓練データへの適合

非ゼロパラメーターの個数に対する罰則

- 最適化的に扱いつらい $\|\theta\|_0$ の代理として $\|\theta\|_1$ を使うというアイデア
 - 非ゼロ成分の個数を数える代わりに、非ゼロ成分の絶対値を足し上げる
 - ℓ^1 -ノルムによる正則化を **Lasso** (least absolute shrinkage and selection operator) とよぶ
- $\|\theta\|_0$ に比べて $\|\theta\|_1$ は最適化の方法がある
 - 解の公式はないのでこれまでにでてきた最適化手法とは違う手法が使われる

ℓ^1 ノルム正則化 (Lasso)

■ 変数選択効果

- $\|\theta\|_0$ とは違うが、それでも、**予測の役に立たない変数は重みを0にしてしまったほうが目的関数が小さくできるので、関係の弱い変数の重みを積極的に0にするようにはたらく**
- 線型モデルでのLassoは、正則化項を通して**変数選択**する手法ともいえる

■ L2正則化でも同じ効果があるんじゃないの？と思うかもしれないが、多少はあるものの、Lassoのほうが積極的に0にする効果が強いことが知られている

■ 両方を使うという手法もあり (ElasticNet) , これもスパース性を誘導する

$$J(\theta) = C(\theta) + \lambda_1 \|\theta\|_1 + \lambda_2 \|\theta\|_2^2$$

質問（続き）

Lassoを使う場合などに、タスクを混同しないことは重要です：

- ・ 予測を良くしたいのか？
- ・ それとも、データの性質を分析して、そこから何か発見をしたいのか？
- ・あるいは、性能をあまり落とさずにモデルの計算を高速化したいのか？

など、「自分が解きたいタスクは何か」を把握して、明言して使わないと、何をしたかったのか自分でもわからなくなってしまうことがあります。

まずタスクをはっきりさせて、それから手法をどうするか考えるという順番が大原則である、ということを頭に置きながら使うことが一つのコツです。

加点对象の質問

モデル選択の際、検証データでの評価が最小になるようにハイパーパラメーターを選びますが、検証データそのものに過学習してしまうというリスクはないのでしょうか？ もしある場合、どうやって防ぐのが一般的ですか？

良い質問ですね。私も昔、同じことが気になって調べました。

昔の論文 (Ng, 1997) などでは「検証データで文字通りのベスト」の代わりに「検証性能で上からX%目に位置していたもの」を使うことが提案されていたりしますが……
(AI系の論文は大多数が無料公開なので気軽にダウンロードして見てみてください)

質問（続き）

実務上は「検証データが十分にあって、かつ、試すハイパーパラメーター候補が多すぎなければ（何百通りも試したりしなければ）大丈夫」と考えることが多いです。

ハイパーパラメーターを少し変えてみて、結果が劇的に違わなければOKとする、ということも実務的には行われます（「感度分析」や「ablation study」といいます）。

背後の考え方の一つに統計的学習理論というものがあり、その枠組みでは「モデルの柔軟さ（キャパシティ）が大きいと過適合の余地が大きい」という考え方をします。

質問（続き）

通常の学習は実ベクトルのパラメーターを最適化したりするので「無限通りのパラメーターから好きに選んでいいよ」という問題を解いています。
そうすると、自由度が高いため過適合の余地が生まれます。

一方、ハイパーパラメーター選択は、無限通り試したりするわけではないので、過適合の余地がその分だけ少ないわけです。


（種明かし：講義序盤の1次関数モデルでは過適合がみられなかったのは、実は、パラメーターが2個しかないモデルだったためです。最初から過適合の説明ですと流石にややこしくなるので、最序盤には1次関数という超簡単なモデルを持ってきました）

【補足】このページは加点対象です。【補足】統計的学習理論の基本的な要点は「仮に過適合していてもこの程度の差で済む」という定理の形式を取ることが多く、大まかに言えば「真のリスクが高いなら訓練データでも（データの出方に関して）高確率で同じくらい予測が悪いはず」という主張の形を取ることが多い。

告知

- 小テストは順次公開しています。毎回のあとの月曜頃に見てください。
- 「ここまでの振り返り」スライドをアップしてあるので活用してください

ロードマップ






モデル選択（ハイパーパラメータ選択）（前回の残り）

正則化係数の選び方

L2正則化を使うとき、 λ の値はどのように決めればよいのか？

- 正則化係数 λ の大きさによって、正則化の強さを調整し、過適合を抑制できる



正則化無し 0 $\longrightarrow$ λ 正則化強

用語＞ハイパーパラメーター (Hyperparameters)


正則化係数の他にも、決めなくてはならないものは色々ある

■ ハイパーパラメーター (hyperparameters)

- モデルの訓練前に選んで固定するパラメーターのこと

■ 例

- モデルの複雑さに関わるもの（多項式モデルの最大次数 r など）
- 正則化に関わるもの（L2正則化の正則化係数 λ など）
- 最適化手法に関わるもの（勾配法の学習率 η など）
- そもそもどのようなモデルを使うか（モデル選択）
- そもそも特徴量として何を含めて何を含めないか（変数選択）



ハイパーパラメータ選択



モデル選択規準の値の大小で選べばよい

- 言い換えれば、ハイパーパラメータ選択という最適化問題を解けばよい


$$\underset{\lambda \in \Lambda}{\text{Min Criterion}}(\lambda)$$

- ここで $\text{Criterion}(\lambda)$ はハイパーパラメータ λ を用いて学習～検証を行なって得られるモデル選択規準の値。ここでは、小さいほど良い指標とする。
- $\text{Criterion}(\lambda)$ は、1つの λ に対して値を計算するために1回学習～検証をするので、大きな計算時間と計算費用がかかる傾向にある。

モデル選択 > 検証曲線 (Validation Curve)

ハイパーパラメーターを1つ選ぶだけならば，色々試してプロットすればよい

- **検証曲線**：ハイパーパラメーターの値に対して検証損失値をプロットしたもの




【補足】 もちろん，他のモデル選択規準を用いる場合は，その指標値をプロットして同様のことをすればよい。

モデル選択＞複数ハイパーパラメーターの最適化

ハイパーパラメーターが複数ある場合、そうもいけなくなる


- ハイパーパラメーターが複数ある場合、組合せとして最適なものを選びたい
- ただし、関数のグラフは見えない状態で最適点を見つける必要がある



モデル選択 > グリッドサーチ

多数のハイパーパラメーターを，愚直に総当たりで試すのは得策ではない


- グリッドサーチ（grid search）：全ての組み合わせを総当たりする方法
 - 少数なら実行可能だが，例えば5つのハイパーパラメーターを各8水準から探索するなら， $8^5 = 32,768$ 回の学習～評価を繰り返すことになり非現実的



モデル選択 > ランダムサーチ

総当たりできない場合のための様々な方法が研究されている


- ランダムサーチ (random search)
 - 何らかの確率分布でハイパーパラメーターをランダムにサンプリング
 - グリッドサーチと比べて満遍なく全体をカバーしている



モデル選択 > ベイズ最適化

総当たりできない場合のための様々な方法が研究されている


- ベイズ最適化 (Bayesian optimization)
 - モデル選択規準の値を目的関数として、最適化問題を解く方法
 - 計算済みの目的関数値の情報から、当たりをつけながら逐次的に探索する



モデル選択 > ハイパーパラメーター探索の実験

以下の関数を最小にする (λ_1, λ_2) を探索



- 関数 $\text{Criterion}(\lambda_1, \lambda_2)$ (値が小さいほど良い, 赤色で表示)
 - 少ない評価回数で, 効率よくハイパーパラメーター選択をしたい




モデル選択 > 実験結果

ランダムサーチやベイズ最適化を用いることで高効率に


- 手軽なのはランダムサーチ（並列化しやすい）
- 賢く実行する必要があるらベイズ最適化



グリッドサーチ：5.9848



ランダムサーチ：2.9773



ベイズ最適化：0.9219

モデル選択 > まとめ




ハイパーパラメーター選択／モデル選択は，モデル選択規準で行うのが基本

- 最適化問題を解くことによりハイパーパラメーターを選ぶ

$$\underset{\lambda \in \Lambda}{\text{Min Criterion}}(\lambda)$$

- モデル選択規準 $\text{Criterion}(\lambda)$ は色々あるが検証データの置き置き法が基本
- 最適化の方法も色々
 - グリッドサーチ（総当たり）よりはランダムサーチのほうがよいとされる
 - より少ない試行回数で良い解を探したい場合はベイズ最適化もある（ただし並列化が難しくなるので，一気に試すならランダムサーチのほうが相性が良い）

ロードマップ



学習の枠組み（まとめ）

学習の枠組みまとめ



多くの手法に共通する基本概念が出揃ったので、ここで一度まとめておきます

- ここまで、**予測タスクのための教師付き学習**を説明してきた
- その中で、次のようなキーワードが出てきた

予測タスク 教師付き学習

モデル リスク 経験リスク 目的関数 最適化

過適合 正則化 モデル選択

学習の枠組み（まとめ） > ①タスクと学習戦略を設定


タスクを定めて，そのための学習戦略を決める（教師付き学習など）

- **タスク**を定める ← 達成させたい仕事の言語化

「〇〇から△△を予測する，という予測タスクを実行したい」


- **学習戦略**を決める ← データの集め方や仮定・事前情報からなる問題設定

「ラベル付きデータを用意し，教師付き学習で学習（データはi.i.d.）」




学習戦略

=



集めるデータ

+




補助情報・事前知識

学習の枠組み（まとめ） > ②モデルと損失関数を選定

予測器の素材となるモデルを選び，良さの指標となるリスクを定義

- モデルを選ぶ ← 予測器の候補とする



- リスク（期待損失）を定義 ← 損失関数を選ぶことで定義される

$$R(f) := \mathbb{E}_{(X,Y) \sim p}[\ell(Y, f(X))]$$

データの生成分布による期待値

損失関数で予測誤差を測る

「例：二乗損失 $\ell(y, y') := (y - y')^2$ で予測誤差を定義する」

【補足】 損失関数は，一般化して，ラベル付きデータ $Z = (X, Y)$ と関数 f に対して $\ell(Z, f)$ とする場合もある。

学習の枠組み（まとめ） > ③ 目的関数を設計～最適化

目的関数を設計して（経験リスク＋正則化項など），最適化

■ 目的関数を設計 ← 学習結果が望ましいモデルになるようにうまく設計する

- 例 1）経験リスク最小化

$$L(\boldsymbol{\theta}) := \hat{R}(f_{\boldsymbol{\theta}})$$

- 例 2）正則化付き経験リスク最小化

$$L(\boldsymbol{\theta}) := \hat{R}(f_{\boldsymbol{\theta}}) + \lambda \cdot \Omega(\boldsymbol{\theta})$$

$$(\Omega(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|^2 \text{ など})$$

■ 目的関数の最適化を介してパラメーターを決定 ← この過程が学習


$$\text{Min}_{\boldsymbol{\theta}} L(\boldsymbol{\theta})$$

学習の枠組み（まとめ） > ④モデル選択と評価

正則化係数など、選ばなければならないハイパーパラメーターがあれば選択

■ ハイパーパラメーター選択（モデル選択）を行う ←モデル選択規準を使う

- 検証・交差検証なら，「学習→検証データで評価」をハイパーパラメーターの候補の数だけ繰り返す



- 最終的には，最良なハイパーパラメーターで学習した予測器を使用する

■ 最終性能評価も行う場合は，学習～検証に使わなかった評価用データで評価する

統計的機械学習 (Statistical Machine Learning)

データに潜む規則や構造を抽出するための、主要なアプローチの1つ

- **統計的機械学習**：データに潜む規則や構造を、**統計的な考え方に基づいて抽出**することによって、未知の現象に対する予測や現象の理解を行う技術
- データから規則性を見つけると言ったのはいいものの、はいこれを使ってねとデータを渡されたところで、そこからどう処理して、何の情報をどう抽出すればよいかわからない
- その答えの一つであり、現在至るところで成果が上がっているのが、統計的学習

学習の哲学

ここまでに出てきた仮定

実は仮定が色々あった

■ 出てきた仮定

- データの従う確率分布があるという考え方
- 訓練データと未知のデータはその生成分布からのi.i.d.なサンプル
- 特定のモデルで十分な表現力がある（欲しい予測器を十分に表せる）




■ 疑義をつけることはできる

- データは生成分布なんてものを本当に持つのか？サンプルはi.i.d.としていいのか？本当に自分が欲しい予測器はそのモデルで表せるくらい単純なのか？

仮定の必要性

こういった仮定を無くすとどうなるのか？

- 有限のデータしかないのに，どんな未知データにも対応できる予測器を作るということ自体が，そもそも無理な話



- しかし，そう言っていては何にもできないので，できる限りどうにかしようというのが，統計的学習の試み

機械学習における「仮定」にまつわる話



ここから、機械学習と「仮定」について2つの話をします

■ ①必要悪

- 何らかの仮定は置かざるを得ない

■ ②非自明性の源泉

- 実は、こういった仮定こそが、機械学習の手法を有用なものにしている

経験からの知識形成

私たちは、経験則に頼って生活している

■ 太陽は東から昇る

- 私たちは、このことを「知識として知っている」
- その根拠は「昨日も一昨日も、ずっとそうだった」という経験則にある。




■ しかし、本来は、あす太陽が西から昇る可能性だってある

- 物理学があるじゃないかと思うかもしれないが、次の瞬間に物理の法則が変化しないという根本的な保証は無い（物理法則が変化しないこと自体が経験則）


経験からの知識形成＞帰納と演繹

このような経験的知識の形成の論理は帰納的推論と呼ばれる

- **帰納 (induction)** : 限られた事例から, 一般的な法則を導く推論




- **演繹 (deduction)** : 既知の法則から, 論理的に従う正しい結論を導く推論



経験からの知識形成＞帰納的推論の困難

人は経験から知識を形成しようとするが、なぜそれでよいのかは誰も知らない

- 論者「今朝までは太陽は東から昇ったが、明日は西から昇るかもしれない」



- そんなはずはないと言いたいが……
 - 帰納的推論を正当化しようとする、その過程で帰納的な論理を使ってしまう
 - これを**帰納の問題 (The Problem of Induction)** という

経験からの知識形成＞帰納的推論の困難

人は、何かしらの仮定や信念を手掛かりにして、帰納の問題に対処している

- 実際は、そんなことを言っていては何もできなくなってしまうので、人はそれほど気にせずに帰納的推論を日々行なっている
 - 2日前も1日前も太陽は東から昇った。明日も東から昇るだろう。
 - 物理法則は（ほぼ）変化しないという **自然の斉一性** (Uniformity of Nature) を「信じて」あるいは「便宜上仮定して」行動をとる



経験からの知識形成＞統計的学習と帰納的推論

統計的学習は帰納的推論に似ている

■ 統計的学習

- 有限のサンプルから、未知のサンプルにも使えるような汎化した予測器を作る
- この形の学習問題設定は、帰納的学習（inductive learning）と呼ばれる。

■ データの「本当の出方」は誰にも分からない

- 実際は、そんなことを言っていては話が進まないのので、推論をできるように「便宜上の仮定を置いて」学習を行う

【補足】 帰納的ではない学習問題設定の例として、初めから特定の入力値に対してだけ予測を出せば良い（その場合、予測器を一旦作る必要などではなく、幾つかの予測値を直接決めることが解決策になりうる）という問題設定がある。

機械学習手法と仮定 > ①帰納的推論のための必要悪

帰納的推論と同様の根本問題があるので、何らかの仮定は置かざるを得ない

- 有限のサンプルから、一般化を可能にするための便宜的な仮定が必要
 - 未知のデータと手元のデータを結びつける要素が何かないといけない
 - ▶ 例えば「生成分布の存在」を仮定したり「i.i.d.サンプル」と仮定したり
- これには根源的な理由があるので避けられない

②非自明性の源泉＞ノーフリーランチ定理

万能な手法は存在しない

- ノーフリーランチ”定理” (No-free-lunch theorem)

- 「あらゆるケースで優れた性能を発揮する、万能な手法は存在しない」

- 名前は ”There ain’t no such thing as a free lunch.” という格言に由来

- 「何も支払わずに何かを手に入れることはできない」という意味


【補足】 “There ain’t no such thing as a free lunch.” というフレーズから、19世紀の米国のサロンには、ワンドリンク制で無料のランチを提供している店が多くあったという。しかし、ドリンク代にランチ分が含まれているはずなので、結局無料の昼食は手に入らない。懐を痛めずに何かを得られるうまい話はないという喩え。

【参考】 Wolpert, D. H. (2002). The supervised learning no-free-lunch theorems. In *Soft Computing and Industry: Recent Applications* (pp. 25–42). Springer.

【参考】 Goldblum et al., (2024). Position: The no free lunch theorem, Kolmogorov complexity, and the role of inductive biases in machine learning. *Proceedings of the 41st International Conference on Machine Learning (Position Paper Track)*, 235, 15788–15808.

②非自明性の源泉＞ノーフリーランチ定理

ある特定領域で高性能にしようとする、他の部分がどこか犠牲になる



②非自明性の源泉＞ノーフリーランチ定理の含意

手法が他よりも優れるためには、**どんな問題が出るかヤマを張るほかない**

- アルゴリズムが有用になるのは、特定の仮定にコミットした場合のみ
 - 仮定が外れていれば大失敗するリスクを負う
 - その代わりに、成功できる可能性が生まれる
- 対称性を破るような、非自明な要素がなければ有用になり得ない



【補足】 実際のノーフリーランチ定理は悲観的すぎるようにも思える。この講義では「手法が他よりも優れるためには、非自明性の源泉となる仮定や事前知識が必要
なはずだ」という、人々が共通認識として持っている信念・観念の一種として紹介する。

機械学習手法と仮定＞②非自明性の源泉

この観点では、仮定こそが有用な手法の源泉ともいえる

- 「仮定を置く」 ≡ 「特定の問題設定に特化する」 ≡ 「事前知識（信念）を込める」
- 仮定は強すぎても弱すぎても良くない
 - 仮定が強すぎる→仮定が的外れだと、結果として性能が出ない😓
 - 仮定が弱すぎる→本来使える知識を捨てているということになる😓
- ある程度は正しいと思えるような仮定なら、便宜的なものと割り切って積極的に使うのが吉

機械学習手法と仮定＞②非自明性の源泉＞事前知識

仮定＝信念という気持ちを込めて事前知識ということがある

■ 事前知識 (prior knowledge)

- 事前に正しいと分かっている（信じている）情報
- 特に、特定の分野に関する **ドメイン知識 (domain knowledge)**
- 例) 「この特徴量がこの分野では有効」 「このモデルがこの分野では有効」

■ データ + 事前知識, が学習アルゴリズムに渡されている, という考え方をする

- 事前知識も情報源 (“ノーフリーランチ”の対称性を破る要素)
- **データが少ないとき**ほど, 強い事前知識が必要

機械学習手法と仮定＞②非自明性の源泉＞帰納バイアス

積極的な意味を込めて帰納バイアスともいう

■ 帰納バイアス (inductive bias)

- 帰納的学習・帰納的推論をする上で、（事例に整合的なあらゆる仮説の中で）どのような仮説を好むか、という偏りや、偏らせるための措置のこと。
- 例）「似通った訓練損失値なら、パラメーターノルムが小さい予測器がよい」

■ 「正しいとは言わないが、わざと偏らせています」という意味で帰納バイアス

- 他の一般化もあり得る中で、特定の結論をあえて選ぶように偏らせる要素
- 「何を学習すべきか」という範囲を絞り込んで狭める役割を持つ

機械学習手法と仮定＞帰納バイアス＞オッカムの剃刀

代表的な帰納バイアスで、倏約の法則（the principle of parsimony）とも。

■ オッカムの剃刀（Occam's razor, オッカムのかみそり）

- 物事を説明するために導入する仮説は、必要以上に複雑であってはならない



■ 以下のようなアナロジーで用いられる

- 訓練損失が同程度なら、パラメーターの個数が少ないモデルほどよい
- 訓練損失が同程度なら、パラメーターのノルムが小さいモデルほどよい

【画像】 https://commons.wikimedia.org/wiki/File:William_of_Ockham_-_Logica_1341.jpg

【補足】 オッカムは地名だが、この文脈ではイングランドの哲学者・神学者であるWilliam of Ockhamのことを指す。

帰納バイアス > まとめ



機械学習手法の違いは，仮定 $\equiv$ 帰納バイアス $\equiv$ 事前知識の違い

- 万能的に優れた手法は存在しない．あるのは，特定の分野に秀でた特化型の手法
 - 仮定が正しい $\rightarrow$ 高性能を出せる余地あり．仮定が誤り $\rightarrow$ 大失敗の危険あり
- **現実の問題にうまく合致した**事前知識や帰納バイアスを組み込むことで，優れた学習手法を開発できる余地が生まれる
 - 多くの研究は新しい帰納バイアスやその取り込み方を開発するものともいえる
- 機械学習の手法には，色々な帰納バイアスや事前知識が組み込まれている

帰納バイアス＞私見



では、なぜ「この分野ではこの手法が最強」という噂が聞こえてくるのか？

- ノーフリーランチ定理は悲観的すぎる
 - どんな問題が出現するか分からない，混沌とした世界を相手にしている
- 人間が解きたい課題は，似通っていたり，思った以上に単純だったりするのも
 - だとすれば，これは「共通して使える事前知識」にほかならない


リスク最小化と近似ターゲット

基本知識の確認＞同時分布（Joint Distribution）


多変数の確率分布を**同時分布**という

- 例えば, (X, Y) というペアの同時確率密度

$$p(x, y)$$



同時密度 $p(x, y)$



$p(x, y)$ を真上から見た等高線


【用語】 日英で対応する用語は、同時確率分布 = simultaneous probability distributionと、結合確率分布 = joint probability distributionだが、英語ではjoint probability distribution, 日本語では同時確率分布ということが多い。 【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認＞周辺分布（Marginal Distribution）


多変数の一部だけを見た分布を**周辺分布**という

- 例えば, X を無視して Y だけを見た周辺密度 $p(y)$ は, 同時密度から次式で計算

$$p(y) = \int p(x, y) dx$$



同時密度 $p(x, y)$



同時密度 $p(x, y)$

周辺密度 $p(y)$

【補足】 どの変数の周辺分布かが分かるように $p_Y(y)$ と書く場合もある。 【用語】 上で入りきらなかったので略称にしたが, 正式には当然, 周辺確率分布 (marginal probability distribution) という。 【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認＞条件付き分布（Conditional Distribution）


一部の変数の値が分かっているときの分布を**条件付き分布**という

■ 例えば、 X で条件付けた Y の条件付き密度 $p(y|x)$ は、次式で計算


$$p(y|x) = \frac{p(x, y)}{p(x)}$$

y での積分が1になるように規格化


同時密度の断面の関数
(規格化すると条件付き密度になる)



同時密度 $p(x, y)$



同時密度 $p(x, y)$ のスライス



条件付き密度 $p(y|x)$

【補足】 上式の記法 $p(y|x)$ は見やすいが、分からなくなったら「事象 $X = x_0$ を条件付けた Y の分布が $p(y|x = x_0) = p(x_0, y) \left(\int p(x_0, y') dy' \right)^{-1}$ 」と理解しておけるとよい。

【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認 > 条件付き分布 > 基本性質

条件付き密度の便利な式変形

- 同時密度 $p(\mathbf{x}, y)$ から、条件付き密度 $p(y|\mathbf{x})$ へ

- 一部の変数を「条件部に移す」操作ができる

$$\underset{\substack{\text{→} \\ x \text{ を条件部にしたい}}}{p(\mathbf{x}, y)} = p(y|\underset{\substack{\text{←} \\ x \text{ が条件部になった}}}{\mathbf{x}}) \overset{\text{→}}{p(\mathbf{x})} \quad \text{周辺分布が外に繰り出された}$$

- 条件付き密度 $p(y|\mathbf{x})$ から、同時密度 $p(\mathbf{x}, y)$ へ

- 条件部と同じ周辺分布を掛けると、「条件部から戻す」操作ができる

$$\underset{\substack{\text{↑} \\ p(x) \text{ を掛けると条件部から戻せる}}}{p(y|\mathbf{x})} \cdot \underset{\text{↑}}{p(\mathbf{x})} = \underset{\substack{\text{←} \\ x \text{ が条件部から左に戻った}}}{p(\mathbf{x}, y)}$$

基本知識の確認 > 条件付き期待値 (Conditional Expectation)




条件付き分布による期待値を**条件付き期待値**という

- $X = x$ を所与とした Y の条件付き期待値は, $p(y|x)$ に関する期待値のこと

$$\mathbb{E}[Y|X = x] = \int y \cdot p(y|x) dy$$

- これは x の関数になっている (x ごとに1つの値が決まる)

各点 x ごとの期待値を
プロットしたものが
 $\mathbb{E}[Y|X = x]$




$X = 8$ の条件付き分布

基本知識の確認＞分位点 (Quantile)

全体のうち割合 α がこの値以下である，という点を α -分位点 という

■ Y の分布関数を $F(y) := \mathbb{P}(Y \leq y)$ とすると， Y の α -分位点 (α -quantile) は，

$$F^{\leftarrow}(\alpha) := \inf\{y \in \mathbb{R} \mid F(y) \geq \alpha\}$$



この点より左に
全体の95%が含まれる

【補足】 α -分位点の定義では $\inf$ が使われている。これは分布関数にジャンプがある場合を考慮したものである。正確には，「この点より大きい点であれば，左側に割合 α 以上が含まれる」という最も小さい値として定義されている。 【用語】 α をパーセントで表す場合，percentileという。

【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認 > 条件付き分位点




条件付き分布における分位点を**条件付き分位点**という

- $X = x$ を所与とした Y の条件付き分布関数を $F(y|x) := \mathbb{P}(Y \leq y|x)$ とすると,
- $X = x$ を所与とした Y の**条件付き α -分位点** (**conditional α -quantile**) は,

$$F^{\leftarrow}(\alpha|x) := \inf\{y \in \mathbb{R} \mid F(y|x) \geq \alpha\}$$

- 例) 条件付き90%分位点

各点 x ごとの α -分位点を
プロットしたものが
 $F^{\leftarrow}(\alpha|x)$




$X = 8$ の条件付き分布

基本知識の確認＞分位点と期待値の関係

期待値は，集団から離れた値に引っ張られやすい

$$\mathbb{E}[X] = \int x \cdot p(x) dx$$


(無視できない重み $p(x)$ をもつ)
大きな値が混ざっていると、
全体に大きな影響が残る



基本知識の確認＞分位点と期待値の関係

分位点は，期待値と比べて，離れた値に影響されにくい


- 中央値は期待値よりも外れ値に影響されにくい
 - 要約としては期待値よりも使いやすい場合がある（数個の分位点でもよい）



これまでの考え方

学習は、用意したモデルの中で最良のものを目指して行う

- まずは、予測器の雛形となるモデルを用意する
- そして、そのモデルのパラメーターの中で、リスクがなるべく小さいものを探す



近似ターゲットという考え方

「モデルの中」ではなく，あらゆる関数の中でリスク最小化を考えてみる


■ モデルの外部のことまで考えた話

- モデルの学習の目標は，**近似ターゲット (approximation target)** にできるだけ近い関数を手に入れること

あらゆる予測器

本当に
リスク最小の関数
(近似ターゲット)

f^*



【用語】 近似ターゲットという用語はこの講義内のもの。一般に浸透している用語ではないので注意（ただし分かりやすいと思う）。文脈によっては推定対象（estimand）と呼ぶこともある。【補足】 理論的に取り扱うときは，文字通りあらゆる関数ではなく，適当に滑らかな関数全体を考えるのが普通である。

近似ターゲットと関数近似器としてのモデル



リスク定義をした時点で、最適な予測器は決まっている


- 近似ターゲットは何によって決まるか？
 - リスク関数が定義された時点で決まる
 - つまり、損失関数とデータの生成分布によって決まっている
- この観点からは、**モデルは関数近似器**であるともいえる
 - モデルによって近似ターゲットをできるだけ近似しようとしている
 - （モデルが表現できる中で最も近いものを目指している）

近似ターゲット > 期待二乗誤差の場合

二乗誤差を損失関数とする場合の近似ターゲットは、**条件付き期待値関数**


- 二乗誤差 $\ell(y, y') = (y - y')^2$ の場合、リスク関数は期待二乗誤差

$$R(f) := \mathbb{E}(Y - f(X))^2$$



- この場合の近似ターゲットは、**条件付き期待値関数 (conditional expectation)**

$$f^*(x) := \mathbb{E}[Y|x]$$



近似ターゲットと損失関数の設計



これを逆手に、欲しい関数が近似ターゲットにするように損失を設計することも


- ①先に使いたい損失関数／リスクが決まっている（これまで）
 - →何が近似ターゲットかは後から検討する

- ②逆に、近似したい関数が先に決まっている
 - →それが近似ターゲットになるよう損失関数を選ぶ／設計する

分位点回帰

次のようなデータの場合の、回帰タスクを考える

- 例) 主な予測対象の集団と、一部の外れた対象がいる
 - 下の集団を重視して予測器を作りたい




この辺りは重視しない

主な予測対象としたい

分位点回帰

条件付き期待値では，集団から離れた少数に引っ張られやすい

- 条件付き中央値のほうが，条件付き期待値よりも予測器として妥当な場合がある
 - モデルによって条件付き中央値を近似したい




近似ターゲット > 条件付き分位点

近似ターゲットを条件付き分位点にするために、ピンボール損失を使う

- 損失関数としてピンボール損失 (pin-ball loss) を用いるとき、


$$\ell_{\alpha}(y, \hat{y}) := \begin{cases} (1 - \alpha) |y - \hat{y}| & (y - \hat{y} < 0) \\ \alpha |y - \hat{y}| & (y - \hat{y} \geq 0) \end{cases}$$



リスクは $R(f) = \mathbb{E}[\ell_{\alpha}(Y, f(X))]$ であり、

- 近似ターゲットは、条件付き α -分位点 (conditional α -quantile) になる

$$f^*(x) = F^{\leftarrow}(\alpha | x)$$



【補足】 ここで $\alpha \in (0,1)$. 【用語】 ピンボール損失という名称は、ピンボールを打った軌道のような見た目から、チェックマークの形状のため、チェック損失ともいう。分位点損失 (quantile loss) ともいう。 【参考】 Koenker, R., Bassett, G., Jr., 1978. Regression quantiles. *Econometrica* 46, 33–50.

近似ターゲット > 条件付き中央値

近似ターゲットを条件付き中央値にするためには、絶対誤差を使えばよい



- 絶対誤差 (absolute error) $\ell(y, \hat{y}) = |y - \hat{y}|$ の場合、リスク関数は、

$$R(f) := \mathbb{E} |Y - f(X)|$$

- これは、 $\alpha = 0.5$ のピンボール損失と等価

- この場合の近似ターゲットは、**条件付き中央値関数 (conditional median)**

$$f^*(x) := \inf\{y \in \mathbb{R} \mid \mathbb{P}(Y \leq y \mid x) \geq 0.5\}$$




近似ターゲット > 分位点回帰 > 実験

人工データで分位点回帰の実験

■ L2正則化付き最小絶対誤差回帰 $L(\theta) = \sum_{i=1}^n |y_i - f_{\theta}(x_i)| + \lambda \cdot \|\theta\|^2 \rightarrow \text{Minimize}$

- モデルは20次多項式関数, λ は20個ほどの候補から検証損失値により選択



訓練データ


【実験ソースコード】 [番号]_quantile_regression.ipynb

【補足】最適化の手法の説明は省略するが、線型計画問題 (linear programming problem) の汎用的な手法を用いて解ける。


近似ターゲット > 分位点回帰 > 実験

人工データで分位点回帰をした実験の結果

- 訓練済みモデルの近似ターゲットが，条件付き中央値になった様子が見てとれる



訓練データと訓練済みモデル



条件付き期待値

訓練済みモデル

真の条件付き中央値

訓練データと訓練済みモデル

リスク最小化と近似ターゲットまとめ



モデルは、最良の予測器に対する、関数近似器とみることも多い


同じ手法の異なる見方

(考えているモデルの中で)
リスクの値ができるだけ小さくなる
ようにパラメーターを調整



(あらゆる予測器の中で)
近似ターゲット
= リスク最小の理想的な予測器
をモデルで近似

ロードマップ



リスク最小化と近似ターゲットの証明（付録）

近似ターゲットの証明アウトライン



ここまでにでてきた最適性の証明のあらすじを掲載しておく

- (注意) これは証明のアウトラインであり，厳密な証明ではない
- (参考) 厳密な証明にするために，少なくとも必要な修正
 - 特徴量空間・ラベル空間がどのようなものか定義
 - 「あらゆる関数」ではなく可測性などを満たす関数で考える
 - 結論は「確率 1 で等しい」などの形で書き直す

基本知識の確認＞条件付き期待値の性質

$\mathbb{E}[Y|x]$ と $\mathbb{E}[Y|X]$ という2つの異なる記号が出てくることがある

- $\mathbb{E}[Y|x]$ は $p(y|x)$ による条件付き期待値
 - これは, x を決めるごとに値が決まるので, $f(x) := \mathbb{E}[Y|X = x]$ という関数
- $\mathbb{E}[Y|X]$ は, 関数 $\mathbb{E}[Y|x]$ に X を代入したもの (X に由来して確率変数になる)
 - つまり $f(X)$ という新たな確率変数

基本知識の確認＞条件付き期待値の性質

条件付き期待値の条件部について，重ねて期待値をとるとどうなるか

■ 繰り返し期待値の公式 (law of iterated expectations)

$$\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]]$$

■ 詳しく書くなら，

$$\underbrace{\int y \cdot p(x, y) dx dy}_{\mathbb{E}[Y]} = \int \left(\int y \cdot p(y|x) dy \right) p(x) dx = \int \underbrace{(\mathbb{E}[Y|X=x]) \cdot p(x)}_{\mathbb{E}[\mathbb{E}[Y|X]]} dx$$

【用語】 これには複数の呼び名があり，タワー性質 (tower property) や全期待値則 (law of total expectation) ともよばれる。

【補足】 ここで， $p(y|x)p(x) = p(x, y)$ を使った。

近似ターゲット > 期待二乗誤差の場合 > 証明

期待二乗誤差は、条件付き期待値関数によって最小化される

- 一般の多次元の場合 ($\mathcal{Y} = \mathbb{R}^d$) で示す. $f^*(x) := \mathbb{E}[Y|x]$ とする.

$$\begin{aligned}\mathbb{E}\|Y - f(X)\|^2 &= \mathbb{E}\|Y - f^*(X) + f^*(X) - f(X)\|^2 \xrightarrow{\|a+b\|^2 = \|a\|^2 + \|b\|^2 + 2\langle a, b \rangle} \\ &= \mathbb{E}\|Y - f^*(X)\|^2 + \mathbb{E}\|f^*(X) - f(X)\|^2 + 2\mathbb{E}\langle Y - f^*(X), f^*(X) - f(X) \rangle\end{aligned}$$

- ここで, $\mathbb{E}\langle Y - f^*(X), f^*(X) - f(X) \rangle = \mathbb{E}_X[\mathbb{E}[\langle Y - f^*(X), f^*(X) - f(X) \rangle | X]]$ であり,

$$\begin{aligned}\mathbb{E}[\langle Y - f^*(x), f^*(x) - f(x) \rangle | x] &= \langle \mathbb{E}[Y|x] - f^*(x), f^*(x) - f(x) \rangle \quad (\because \text{線型性}) \\ &= \langle \mathbf{0}, f^*(x) - f(x) \rangle = 0\end{aligned}$$

- よって, $\mathbb{E}\|Y - f(X)\|^2 = (\text{const.}) + \mathbb{E}\|f^*(X) - f(X)\|^2$ であり, 最小化は $f = f^*$ と等価

【補足】 上記は証明のあらすじ. 数学的に厳密に示すには, $L^2(p_X)$ 空間などで証明する. また, 結論部の正確な主張は $f = f^*$ (a.s.- p_X) である. 非負可測関数 f について, $\mathbb{E}[f(X)] = 0 \Leftrightarrow f(x) = 0$ (a.s.- x) (Çinlar, 2011, Proposition 4.13など).

近似ターゲット > 誤識別率の場合 > 証明

誤識別率を最小化するのは、最大条件付き確率則という予測器

- $f^*(x) := \arg \max_{k \in \{1, \dots, K\}} \mathbb{P}(Y = k | x)$ と定義していた。このとき、以下が成立。

$$R(f) = \mathbb{E}[\mathbf{1}\{Y \neq f(X)\}] = \mathbb{E}_X[1 - \mathbb{E}[\mathbf{1}\{Y = f(X)\} | X]] = \mathbb{E}_X[1 - \mathbb{P}(Y = f(X) | X)]$$

$$R(f^*) = \mathbb{E}[\mathbf{1}\{Y \neq f^*(X)\}] = \mathbb{E}_X[1 - \mathbb{E}[\mathbf{1}\{Y = f^*(X)\} | X]] = \mathbb{E}_X[1 - \max_k \mathbb{P}(Y = k | X)]$$

- 辺々引き算して、 $R(f) - R(f^*) = \mathbb{E}_X[\max_k \mathbb{P}(Y = k | X) - \mathbb{P}(Y = f(X) | X)]$ を得る。
- いま、 $\max_k \mathbb{P}(Y = k | X) - \mathbb{P}(Y = f(X) | X) \geq 0$ より、 $R(f) - R(f^*)$ の最小値は 0 で、
最小化の達成条件は $\max_k \mathbb{P}(Y = k | \cdot) - \mathbb{P}(Y = f(\cdot) | \cdot) = 0$ と等価。
さらにこれは、 $f = f^*$ と等価（仮に $f \neq f^*$ なら $R(f) - R(f^*)$ が正の値になる）。

【注意】 上記は証明のあらすじ。正確には結論は $f = f^*$ (a.s.- p_X) になる。複数のクラスが同時に最大確率となる場合は、例えばクラス番号が最も小さいものを予測値とするなど、タイブレイクのルールを任意に決めておく。 【補足】 非負可測関数 f について、 $\mathbb{E}[f(X)] = 0 \Leftrightarrow f(x) = 0$ (a.s.- x) (Çinlar, 2011, Proposition 4.13など)

近似ターゲット > 交差エントロピーの場合 > 証明

交差エントロピーを最小化するのは、条件付き確率。

- 交差エントロピーとKLダイバージェンスは最小化において等価なのでKLで議論。

$$H(p, q) = \text{KL}(p \| q) + (\text{constant})$$

- KLダイバージェンスに対して、Jensenの不等式を用いる。

$$\begin{aligned} \text{KL}(p \| q) &= \int p(x, y) \log \frac{q(y | x)p(x)}{p(y | x)p(x)} dx dy \\ &\geq \log \left(\int p(x, y) \frac{q(y | x)p(x)}{p(y | x)p(x)} dx dy \right) \\ &= 0 \end{aligned}$$

- 等号成立は $q(y | x) = p(y | x)$ のとき、またそのときのみ。

【注意】 上記は証明のあらすじ。正確には結論は $q(y | x) = p(y | x)$ ($p(x, y)$ -a.s.) になる。

近似ターゲット > 分位点回帰 > 証明

ピンボール損失でのリスクは，条件付き分位点関数によって最小化される

■ 定義：

- 損失関数は $\ell_{\alpha}(y, y') := (1 - \alpha)|y - y'| \mathbf{1}\{y - y' < 0\} + \alpha|y - y'| \mathbf{1}\{y - y' \geq 0\}$
- また， $F(y|x) := \mathbb{P}(Y \leq y|x)$ ， $F^{\leftarrow}(\alpha|x) := \inf\{y \in \mathbb{R} : F(y|x) \geq \alpha\}$ と定義.

■ 仮定： $\forall x$ で $F(\cdot|x)$ は狭義単調増加かつ連続と仮定し， その場合でのみ示す.

■ 条件付きリスク $R(b|x) := \mathbb{E}[\ell_{\alpha}(Y, b)|x]$ に着目する.

■ まず，定義から $R(b|x) = \int_{-\infty}^b (\alpha - 1)(y - b)p(y|x)dy + \int_b^{\infty} \alpha(y - b)p(y|x)dy$ であり，

右辺を b で愚直に微分して整理すると ① $\frac{\partial}{\partial b} R(b|x) = F(b|x) - \alpha$ を得る.

【補足】 $\ell_{\alpha}(y, y')$ は $y' = y$ において微分不能だが，それを積分した $\mathbb{E}[\ell_{\alpha}(Y, b)|x]$ であれば微分可能ということ．また，条件付き密度 $p(y|x)$ の存在なども仮定している．

近似ターゲット > 分位点回帰 > 証明

ピンボール損失でのリスクは，条件付き分位点関数によって最小化される

■ 単調性の仮定から $F(b|x) - \alpha$ は狭義単調増加なので，①より $R(b|x)$ は狭義凸。

■ ①と単調性の仮定から， $\frac{\partial}{\partial b} R(b|x) = 0 \iff F(b|x) = \alpha \iff b = F^{\leftarrow}(\alpha|x)$ 。

■ よって $R(b|x)$ は可微分な狭義凸関数で，(微分) = 0 は $b = F^{\leftarrow}(\alpha|x)$ のとき。

よって $\arg \min_{b \in \mathbb{R}} R(b|x) = F^{\leftarrow}(\alpha|x)$ である。特に，狭義凸より最小化元は1点のみであり，任意の $b \neq F^{\leftarrow}(\alpha|x)$ に対して， $R(b|x) > R(F^{\leftarrow}(\alpha|x)|x)$ となる。

■ よって， $R(f) = \mathbb{E}_X [R(f(X)|X)]$ の最小化元は， $f^* = F^{\leftarrow}(\alpha|\cdot)$ に限られる。

【注意】 上記は証明のあらすじ。条件付き密度の存在を仮定したので，上で仮定を追加するまでもなく $F(\cdot|x)$ は可微分，特に連続である。

【補足】 結論部は $f^*(\cdot) = F^{\leftarrow}(\alpha|\cdot)$ (a.s.- X)。 $\mathbb{E}_X [\mathbb{E}[\ell_\alpha(Y, f(X))|X]] = \mathbb{E}_X [\mathbb{E}[\ell_\alpha(Y, f^*(X))|X]]$ ならば $\mathbb{E}[\ell_\alpha(Y, f(x))|x] - \mathbb{E}[\ell_\alpha(Y, f^*(x))|x]$ が非負可測関数であることと，非負可測関数 f について， $\mathbb{E}[f(X)] = 0 \iff f(x) = 0$ (a.s.- x) (Çinlar, 2011, Proposition 4.13など)であることから結論が従う。